

Computer Vision yoʻnalishini yaxshi tushunish uchun oldingi asosiy tushunchalar yana bir marta tartibga solib olinadi. Computer Vision — kompyuterga rasm va videolarni koʻrish, tushunish, tahlil qilish va ulardan maʼno chiqarishni oʻrgatadigan sunʼiy intellekt yoʻnalishi hisoblanadi. Computer Vision qisqartmasi CV shaklida ishlatiladi. “Computer” — kompyuter, “Vision” — koʻrish degani. Shuning uchun Computer Vision oʻzbekchada “kompyuter koʻrishi” deb tushuniladi.

Kompyuter rasmni inson kabi darhol “mushuk”, “it”, “mashina” yoki “odam” sifatida koʻrmaydi. Kompyuter uchun rasm avval raqamlar toʻplami hisoblanadi. Har bir rasm pixel deb ataladigan juda kichik nuqtalardan iborat boʻladi. Pixel — rasmning eng kichik elementi. Har bir pixel maʼlum rang qiymatiga ega. Rangli rasmda odatda 3 ta kanal boʻladi: Red, Green, Blue. RGB — Red, Green, Blue soʻzlarining qisqartmasi. Red — qizil, Green — yashil, Blue — koʻk. Shu uch kanal birlashib rasm ranglarini hosil qiladi.

Image Classification — Computer Visionning asosiy vazifalaridan biri. Image Classification oʻzbekchada “rasmni tasniflash” degani. Bu vazifada model rasmni koʻrib, uni maʼlum bir classga ajratadi. Class — kategoriya yoki tur. Masalan, rasmda mushuk boʻlsa, model `cat` classini chiqaradi. Rasmda it boʻlsa, model `dog` classini chiqaradi.

Image Classificationning bir nechta turi bor. Binary Classification — faqat 2 ta classdan bittasini tanlash. Masalan, `cat` yoki `dog`, `disease` yoki `no disease`. Multi-Class Classification — koʻp classdan faqat bittasini tanlash. Masalan, `cat`, `dog`, `horse`, `deer` classlari ichidan bittasini tanlash. Multi-Label Classification — bitta rasimga bir nechta label berish. Masalan, rasmda odam, mashina va daraxt boʻlsa, model `person + car + tree` deb bir nechta natija chiqaradi. Label — rasimga beriladigan nom yoki belgi.

Image Classification modelini yaratish uchun odatda quyidagi katta bosqichlar bajariladi:

Data Preparation → Model Architecture → Training → Evaluation → Deployment

Data Preparation — ma'lumotlarni tayyorlash. Model Architecture — model tuzilishini yaratish. Training — modelni o'qitish. Evaluation — modelni baholash. Deployment — modelni real ishlaydigan holatga chiqarish.

Data Preparation Review

Data Preparation — Computer Vision projectlaridagi eng muhim bosqichlardan biri. Data Preparation o'zbekchada “ma'lumotni tayyorlash” degani. Model yaxshi o'rganishi uchun dataset toza, tartibli, ma'noli va modelga mos formatda bo'lishi kerak. Dataset — ma'lumotlar to'plami. Image Classificationda dataset odatda rasmlar va ularning class nomlaridan iborat bo'ladi.

Data Preparation jarayonida rasm datasetini tartibli papkalarga joylash kerak. “Data → Folder” tushunchasi shuni bildiradi: rasmlar class nomiga mos papkalarga ajratiladi. Masalan, mushuk va it classification qilish uchun dataset quyidagicha tuziladi:

```
data/
├── cat/
│   ├── cat_001.jpg
│   ├── cat_002.jpg
│   └── ...
└── dog/
    ├── dog_001.jpg
```

```
|— dog_002.jpg  
|— ...
```

Bunday tuzilma “folder-based labeling” deb ataladi. Folder-based labeling — papka nomiga qarab rasmga label berish usuli. Masalan, `cat` papkasidagi rasm avtomatik `cat` labelini oladi. `dog` papkasidagi rasm esa `dog` labelini oladi.

Data Preparationda papka nomlari ma’noli bo’lishi kerak. “Manoli folder” deganda class nomlari aniq va tushunarli yozilgan papkalar tushuniladi. Masalan, `class1`, `class2` kabi nomlar o’rniga `cat`, `dog`, `horse`, `deer` kabi tushunarli nomlar ishlatiladi. Bu datasetni keyin o’qish, tekshirish va modelga berishda qulaylik yaratadi.

Custom image workflow tushunchasi ham muhim. Custom image workflow — o’z rasm datasetini tayyorlashdan modelga berishgacha bo’lgan maxsus ish jarayoni. Bu jarayon odatda quyidagicha bo’ladi:

```
Local folder path → Dataset size → File names →  
Download images → Clean data → Split data → Train  
model
```

Local folder path — kompyuter ichidagi dataset papkasi yo’li.

Masalan:

```
C:/project/data/images/
```

Dataset size — dataset hajmi. Ya’ni nechta rasm borligi, har bir classda nechta rasm borligi. Dataset size model sifati uchun muhim. Agar bitta classda 1000 ta rasm, boshqa classda 50 ta rasm bo’lsa, model ko’p rasmlı classga ko’proq moyil bo’lib qolishi mumkin.

Bunday holat class imbalance deyiladi. Class imbalance — classlar orasida rasm soni juda noteng bo‘lishi.

File names — fayl nomlari. Rasm fayllari tartibli nomlangan bo‘lishi yaxshi. Masalan:

cat_001.jpg

cat_002.jpg

dog_001.jpg

dog_002.jpg

Download images — rasmlarni yuklab olish. Ba’zi datasetlar internetdan avtomatik yuklab olinadi, ba’zilar esa qo‘lda papkaga joylanadi.

Workflow — takrorlanadigan ishlar ketma-ketligi. Computer Vision projectlarida ko‘plab qadamlar qayta-qayta bajariladi. Masalan, rasm yig‘ish, rasmni tekshirish, resize qilish, train-test split qilish, model train qilish kabi. Shuning uchun workflow aniq bo‘lsa, projectni boshqarish osonlashadi.

Dataset manbalari va ularning vazifasi

Computer Visionni o‘rganishda tayyor datasetlardan foydalanish juda foydali. Dataset — model o‘rganadigan ma’lumotlar to‘plami. Tayyor datasetlar yordamida modelni tez sinab ko‘rish, CNN training qilish, preprocessing o‘rganish, model architecture test qilish mumkin.

CIFAR10

CIFAR10 — 10 ta classdan iborat kichik rangli rasm dataset. Bu datasetdagi rasmlar 32x32 o‘lchamda bo‘ladi. 32x32 degani rasm 32 pixel balandlik va 32 pixel kenglikka ega. Color image — rangli rasm. Rangli rasm odatda RGB kanaliga ega bo‘ladi.

CIFAR10 beginner-friendly, ya'ni o'rganishni boshlayotganlar uchun qulay dataset hisoblanadi. U image classification, CNN training va tez experimentlar uchun ishlatiladi. Experiment — tajriba, ya'ni model yoki kodni sinab ko'rish jarayoni.

CIFAR10 orqali quyidagilar o'rganiladi:

rasm datasetini yuklash
rasmni tensor formatga o'tkazish
CNN model train qilish
class prediction qilish
accuracy baholash

Accuracy — model nechta rasmni to'g'ri topganini ko'rsatadigan metric. Metric — model natijasini o'lchaydigan ko'rsatkich.

CIFAR100

CIFAR100 CIFAR10ga o'xshaydi, lekin unda 10 ta emas, 100 ta class bor. Classlar soni ko'p bo'lgani uchun vazifa qiyinroq bo'ladi. Model 100 class ichidan to'g'ri classni tanlashi kerak.

CIFAR100 model generalizationni tekshirish uchun foydali.

Generalization — model oldin ko'rmagan yangi rasmda ham to'g'ri ishlay olish qobiliyati. CIFAR100 classlari ko'p bo'lgani uchun model faqat oddiy belgilarni emas, ko'proq farqlarni o'rganishi kerak bo'ladi.

MNIST

MNIST — qo'lda yozilgan raqamlar datasetidir. Handwritten digit images — qo'lda yozilgan raqam rasmlari degani. MNIST 0 dan 9 gacha bo'lgan raqamlarni o'z ichiga oladi. Bu dataset juda oddiy va beginner-friendly hisoblanadi.

MNIST orqali classification asoslari, preprocessing, neural network basics va simple model training o'rganiladi. Neural network — neyron tarmoq, ya'ni ma'lumotdan pattern o'rganadigan model. Pattern — takrorlanadigan belgi yoki naqsh.

MNISTda rasm odatda grayscale bo'ladi. Grayscale — qora-oq yoki kulrang rasm. Bunday rasmda RGB kabi 3 kanal emas, bitta kanal bo'ladi.

FashionMNIST

FashionMNIST MNISTga o'xshash, lekin raqamlar o'rniga kiyim rasmlari bor. Fashion — moda yoki kiyim-kechak. FashionMNISTda futbolka, shim, oyoq kiyim, sumka kabi classlar mavjud.

FashionMNIST MNISTga qaraganda biroz realroq classification vazifa hisoblanadi. Chunki kiyimlar raqamlarga qaraganda ko'proq shakl va tuzilishga ega. Bu dataset oddiy image classificationdan realroq masalaga o'tish uchun yaxshi bosqich bo'ladi.

SVHN

SVHN — Street View House Numbers. O'zbekcha ma'nosi "ko'cha ko'rinishidagi uy raqamlari". Bu dataset real-world images, ya'ni haqiqiy dunyodan olingan rasmlarga yaqinroq. Unda uylar, ko'chalar yoki binolardagi raqamlar mavjud.

SVHN MNISTga qaraganda qiyinroq. Chunki raqamlar turli fon, yorug'lik va ko'rinishda bo'ladi. Digit recognition in natural scenes — tabiiy sahnalarda raqam tanish degani. Natural scene — haqiqiy hayot manzarasi.

STL10

STL10 — CIFARga qaraganda yuqoriroq resolutionga ega kichik labeled image dataset. Resolution — rasm aniqligi yoki o'lchami. Labeled dataset — har bir rasmga to'g'ri class nomi berilgan dataset.

STL10 classification, representation learning va transfer learning practice uchun ishlatiladi. Representation learning — model ma'lumot ichidagi foydali belgilarni o'rganishi. Transfer learning — oldin katta datasetda o'rgatilgan modeldan yangi vazifada foydalanish.

Flowers102

Flowers102 — Oxford flower dataset bo'lib, 102 ta gul kategoriyasidan iborat. Category — tur yoki sinf. Bu dataset fine-grained image classification uchun ishlatiladi.

Fine-grained classification — bir-biriga juda o'xshash classlarni ajratish vazifasi. Masalan, turli gul turlari bir-biriga o'xshash bo'lishi mumkin. Model ularning mayda farqlarini o'rganishi kerak bo'ladi.

Food101

Food101 — 101 ta ovqat kategoriyasidan iborat real-world image dataset. Food — ovqat. Food101 real-world classification va transfer learning uchun foydali.

Ovqat rasmlarini classification qilish qiyin bo'lishi mumkin. Chunki bir xil ovqat turli ko'rinishda, turli idishda, turli yorug'likda bo'lishi mumkin. Model ovqat shakli, rangi, ingredientlari va ko'rinishidan classni aniqlashga harakat qiladi. Ingredient — ovqat tarkibidagi mahsulot.

OxfordIIITPet

OxfordIIITPet — mushuk va it zotlari rasmlaridan iborat dataset. Pet — uy hayvoni. Breed classification — zotni aniqlash vazifasi. Masalan, oddiy “dog” emas, balki qaysi it zoti ekanini aniqlash.

Bu dataset segmentation basics uchun ham ishlatilishi mumkin. Segmentation — rasm ichidagi obyektни pixel darajasida ajratish. Masalan, mushuk yoki it tanasi qayerda joylashganini aniq ajratish.

Caltech101

Caltech101 — 101 ta obyekt kategoriyasidan iborat dataset. Bu dataset multi-class classification va classical CV experiments uchun ishlatiladi.

Classical CV — deep learningdan oldingi an’anaviy computer vision usullari. Masalan, edge detection, feature descriptors, SIFT, HOG kabi usullar. Edge detection — qirralarni aniqlash. Feature descriptor — obyekt belgilarini matematik tasvirlash usuli.

Torchvision Datasets

Torchvision Datasets — PyTorch ekotizimidagi asosiy dataset hub hisoblanadi. Hub — markaz yoki to‘plam. Torchvision orqali CIFAR10, MNIST, FashionMNIST, Food101 kabi ko‘plab datasetlarni `download=True` orqali yuklab olish mumkin.

`download=True` — dataset lokal papkada bo‘lmasa, internetdan avtomatik yuklash degani. Bu o‘rganish jarayonini osonlashtiradi.

TensorFlow Datasets

TensorFlow Datasets — Machine Learning uchun katta dataset katalogi. TensorFlow — deep learning framework. Framework —

tayyor vositalar to‘plami. TensorFlow Datasets PyTorchdan tashqari boshqa ekotizimdagi datasetlarni ham o‘rganish uchun foydali.

Hugging Face Datasets

Hugging Face Datasets — standard va community datasetlar joylashgan katta platforma. Community dataset — foydalanuvchilar yoki tadqiqotchilar tomonidan joylangan dataset. Hugging Face image datasetlar bilan ishlash, dataset hosting va custom datasetlar bilan ishlashda foydali.

Hosting — fayl yoki datasetni internetda saqlash va ulashish.

Kaggle Datasets

Kaggle Datasets — public dataset platformasi. Public dataset — hammaga ochiq dataset. Kaggle competition datasetlari va project datasetlari uchun juda mashhur. Competition — musobaqa. Kaggle orqali real-world, niche va amaliy datasetlar topiladi. Niche dataset — tor yo‘nalishga tegishli maxsus dataset.

Dataset jadvali misol sifatida olinsa, har bir dataset uchun qisqa tavsif, undan nima o‘rganish mumkinligi va URL manbasi ko‘rsatilgan. URL — internet manzil. Bunday jadval dataset tanlashda juda foydali bo‘ladi, chunki beginner project uchun MNIST yoki CIFAR10 mos bo‘lsa, realroq project uchun Food101, Flowers102 yoki Kaggle datasetlari tanlanadi.

Practice mazmuni

Practice — amaliyot degani. Computer Visionda practice nazariyani kod orqali mustahkamlash uchun kerak. Rasm datasetini yuklash, papka structure qilish, rasmni ko‘rish, tensor formatga o‘tkazish, modelga berish kabi ishlar practice orqali tushunarli bo‘ladi.

Practice jarayonida odatda quyidagi ishlar bajariladi:

dataset tanlash
datasetni yuklash
rasmlarni papkaga joylash
image pathlarni tekshirish
rasm o'lchamini ko'rish
dataset size hisoblash
label va classlarni tekshirish
preprocessing qilish
modelga kiruvchi formatni tayyorlash

Image path — rasm joylashgan manzil. Masalan:

`data/train/cat/cat_001.jpg`

Model rasmni to'g'ri o'qishi uchun path to'g'ri bo'lishi kerak. Agar papka nomi yoki fayl nomi noto'g'ri bo'lsa, dataset o'qilmaydi.

Praktika orqali shuni ko'rish mumkin: Computer Vision modelining natijasi faqat modelga bog'liq emas. Dataset sifati, preprocessing, class nomlari, folder structure va split ham juda muhim.

Model Architecture tushunchasi

Model Architecture — neural network modelining ichki tuzilishi. Architecture so'zi “arxitektura” yoki “tuzilish” degani. Deep Learningda model architecture model qanday qatlamlardan iboratligi, ma'lumot qaysi yo'nalishda oqishi va natija qanday olinishi bilan bog'liq.

Model Architecture “NN strukturasi” deb tushuniladi. NN — Neural Network, ya'ni neyron tarmoq. Neural Network — qatlamlar va neuronlardan tashkil topgan model. Neuron — model ichidagi hisoblash birligi.

Model Architecture inson tanasi bilan solishtirilganda quyidagicha tushuniladi:

Input → Eye

Processing → Brain

Output → Decision

CNNda esa bu quyidagicha bo'ladi:

Input → Image

Processing → Layers

Output → Prediction

Input — kiruvchi ma'lumot. Image Classificationda input rasm bo'ladi. Processing — model ichidagi qayta ishlash jarayoni. Layers — qatlamlar. Output — yakuniy natija. Prediction — model taxmini.

Inson rasmni ko'zi bilan ko'radi, miyasi esa qaror chiqaradi. CNN modelida rasm input sifatida kiradi, qatlamlar rasm ichidagi belgilarni ajratadi, oxirida prediction chiqadi. Masalan, model rasmni cat yoki dog deb tanlaydi.

Neural Network overview

Neural Network ko'p komponentlardan iborat. Har bir komponent model o'rganish jarayonida alohida rol bajaradi.

Neural Network

Neural Network — ma'lumotdan pattern o'rganadigan qatlamli model. Pattern — takrorlanadigan belgi yoki munosabat. Image Classificationda neural network mushuk va itni ajratish uchun quloq shakli, ko'z joylashuvi, jun tuzilishi, yuz shakli kabi belgilarni o'rganishi mumkin.

Neural Network turlari:

MLP

CNN

RNN

Transformer

MLP — Multi-Layer Perceptron. Oddiy ko‘p qatlamli neyron tarmoq.

CNN — Convolutional Neural Network. Rasm bilan ishlashda ko‘p ishlatiladi.

RNN — Recurrent Neural Network. Ketma-ketlik ma’lumotlari uchun ishlatiladi. Masalan, matn yoki vaqt qatori.

Transformer — attention mexanizmiga asoslangan model. Matn, rasm va multimodal vazifalarda ishlatiladi.

Layer

Layer — neuronlar guruhi. Layer ma’lumotni bosqichma-bosqich qayta ishlaydi. Rasm modelida birinchi qatlamlar oddiy qirra va chiziqlarni topadi. Keyingi qatlamlar murakkabroq shakllarni ajratadi.

Layer turlari:

Input layer

Hidden layer

Output layer

Input layer — kiruvchi qatlam. Rasm shu qatlam orqali modelga kiradi.

Hidden layer — yashirin qatlam. Modelning asosiy o‘rganish jarayoni shu qatlamlarda bo‘ladi.

Output layer — chiqish qatlami. Yakuniy class natijasi shu yerda olinadi.

Weights va Bias

Weights va Bias model o'rganadigan parametrlar hisoblanadi. Weight — vazn. Bias — siljituvchi qo'shimcha qiymat.

Weight feature muhimligini belgilaydi. Masalan, model mushukni aniqlashda quloq shakliga ko'proq ahamiyat bersa, shu belgiga tegishli weight kattaroq bo'lishi mumkin.

Bias model hisoblashiga qo'shimcha moslashuv beradi. Model training davomida weights va bias qiymatlarini o'zgartirib boradi.

Learnable parameters — model o'rganadigan parametrlar. Weights va bias shular jumlasiga kiradi.

Forward Pass

Forward Pass — input model ichidan oldinga qarab o'tib, output olinadigan jarayon. Masalan:

Image → Model → Prediction

Rasm modelga kiradi, qatlamlardan o'tadi va yakuniy prediction chiqadi.

Forward Passda model hali o'zini tuzatmaydi. Faqat mavjud weights orqali natija hisoblanadi.

Loss Function

Loss Function — model qanchalik xato qilganini o'lchaydigan funksiya. Loss — xato qiymati. Agar model to'g'ri javobga yaqin

bo'lsa, loss kichik bo'ladi. Agar model noto'g'ri javob bersa, loss katta bo'ladi.

MSE va CrossEntropy loss turlari sifatida ishlatiladi.

MSE — Mean Squared Error. O'zbekcha "o'rtacha kvadrat xato". Ko'proq regression vazifalarda ishlatiladi. Regression — sonli qiymat bashorat qilish.

CrossEntropy — classification vazifalarida ko'p ishlatiladigan loss. Masalan, cat vs dog classificationda CrossEntropy ishlatiladi.

Gradient Descent

Gradient Descent — lossni kamaytirish uchun weights qiymatlarini yangilaydigan optimization algoritm. Optimization — modelni yaxshilash jarayoni.

Gradient — xatoni kamaytirish yo'nalishini ko'rsatadigan matematik qiymat. Descent — pastga tushish. Ya'ni model loss baland joydan pastga tushishga harakat qiladi.

Gradient Descent turlari:

Batch Gradient Descent

Mini-batch Gradient Descent

Stochastic Gradient Descent

Batch Gradient Descent — butun dataset orqali bitta yangilanish qiladi.

Mini-batch Gradient Descent — datasetning kichik guruhlar orqali yangilanish qiladi.

Stochastic Gradient Descent — odatda bitta yoki juda kichik sample orqali yangilanish qiladi.

Backpropagation

Backpropagation — xatoni orqaga tarqatish usuli. Model outputda xato qilganda, xato oxirgi qatlamdan boshlab oldingi qatlamlarga qaytariladi. Shu orqali har bir weight qanchalik o'zgarishi kerakligi hisoblanadi.

Backpropagation Deep Learning training jarayonining eng muhim qismi. U gradientlarni hisoblaydi. Gradientlar orqali optimizer weightsni yangilaydi.

Optimizer

Optimizer — model weights qiymatlarini qanday yangilashni boshqaradigan algoritm. Optimizer training tezligi va barqarorligiga ta'sir qiladi.

Optimizer turlari:

SGD

Adam

RMSprop

SGD — Stochastic Gradient Descent. Oddiy va klassik optimizer.

Adam — amaliyotda keng ishlatiladigan optimizer. Ko'pincha tezroq va barqarorroq o'rganishga yordam beradi.

RMSprop — gradientlarning o'zgarishini hisobga oladigan optimizer.

Learning Rate

Learning Rate — model weightsni yangilash qadamining kattaligi.

Learning rate juda muhim hyperparameter hisoblanadi.

Hyperparameter — trainingdan oldin qo'lda beriladigan sozlama.

Agar learning rate juda katta bo'lsa, model lossni kamaytirish o'rniga sakrab ketishi mumkin. Training unstable, ya'ni beqaror bo'ladi. Agar learning rate juda kichik bo'lsa, model juda sekin o'rganadi.

Learning rate constant yoki scheduler orqali boshqarilishi mumkin. Constant — o'zgarmas. Scheduler — training davomida learning rateni o'zgartirib boradigan tizim.

Activation Function

Activation Function — modelga non-linearity qo'shadigan funksiya. Non-linearity — murakkab, oddiy to'g'ri chiziq bilan ifodalanmaydigan munosabatlarni o'rganish imkoniyati.

Activation Function bo'lmasa, neural network faqat oddiy linear transformatsiyalarni o'rganib qoladi. Rasm ichidagi murakkab shakllarni o'rganish qiyinlashadi.

Activation Function turlari:

ReLU

Sigmoid

Tanh

Softmax

ReLU — Rectified Linear Unit. Manfiy qiymatlarni 0 qiladi, musbat qiymatlarni o'z holida qoldiradi.

Sigmoid — qiymatni 0 va 1 orasiga keltiradi. Binary classificationda ishlatilishi mumkin.

Tanh — qiymatni -1 va 1 orasiga keltiradi.

Softmax — class scorelarni probabilityga aylantiradi. Probability — ehtimollik.

Epoch

Epoch — model butun training datasetni bir marta to‘liq ko‘rib chiqishi. Masalan, datasetda 1000 ta rasm bo‘lsa, 1 epoch davomida model 1000 ta rasmni ko‘radi.

Agar epochs = 10 bo‘lsa, model butun datasetni 10 marta ko‘radi. Epoch soni juda kam bo‘lsa, model yetarlicha o‘rganmaydi. Juda ko‘p bo‘lsa, overfitting bo‘lishi mumkin.

Batch

Batch — training vaqtida bir qadamda modelga beriladigan ma’lumotlar guruhi. Masalan, batch size 32 bo‘lsa, model bir qadamda 32 ta rasm bilan ishlaydi.

Mini-batch training eng ko‘p ishlatiladi. Bu usul xotira va tezlikni muvozanatda ushlaydi.

Overfitting

Overfitting — model training datasetni yodlab olib, yangi data’da yomon ishlashi. Masalan, training accuracy juda yuqori, test accuracy past bo‘lsa, overfitting bo‘lishi mumkin.

Accuracy — to‘g‘ri javoblar ulushi. Test accuracy — model oldin ko‘rmagan test ma’lumotdagi aniqligi.

Overfittingni kamaytirish uchun augmentation, dropout, regularization, ko‘proq data, early stopping kabi usullar ishlatiladi.

Early stopping — validation natija yomonlasha boshlaganda trainingni to‘xtatish.

Regularization

Regularization — overfittingni kamaytirish texnikalari.

Regularization modelni training data'ni yodlab olishdan saqlaydi va generalizationni yaxshilaydi.

Regularization turlari:

Dropout

L2 regularization

Weight decay

Data augmentation

Dropout — training vaqtida ayrim neuronlarni vaqtincha o'chirib turish.

L2 regularization — weights juda katta bo'lib ketishini cheklash.

Weight decay — weights qiymatlarini kichikroq saqlashga yordam beradigan usul.

Evaluation Metrics

Evaluation Metrics — model performance, ya'ni model natijasini baholash ko'rsatkichlari.

Asosiy metrlar:

Accuracy

Precision

Recall

F1-score

Precision — model bir class deb aytganlar ichida nechta to'g'ri ekanini bildiradi.

Recall — haqiqiy classdagi obyektlardan nechta model topganini bildiradi.

F1-score — precision va recall oʻrtasidagi muvozanat.

Backbone, Neck va Head tushunchasi

Image Classification va boshqa Computer Vision modellari koʻpincha 3 ta katta qismga ajratiladi:

Backbone

Neck

Head

Bu nomlar inson tanasi bilan analogiya orqali tushuntiriladi.

Backbone — umurtqa pogʻonasi yoki asosiy tayanch. Neck — boʻyin, yaʼni bogʻlovchi qism. Head — bosh, yaʼni yakuniy qaror chiqaruvchi qism.

Backbone

Backbone modelning feature extraction qiladigan asosiy qismi.

Feature extraction — rasm ichidan muhim belgilarni ajratish.

Backbone rasm ichidagi qirra, rang oʻzgarishi, shakl, tekstura, obyekt qismlari kabi belgilarni oʻrganadi.

Backbone sifatida CNN, ResNet, EfficientNet, MobileNet yoki ViT ishlatilishi mumkin.

Backbone modelning eng muhim qismi hisoblanadi, chunki yakuniy prediction shu ajratilgan featurelarga bogʻliq.

Neck

Neck backbone va head orasida turadi. Neck ajratilgan featurelarni tartiblaydi, birlashtiradi yoki mos formatga keltiradi.

Neck object detectionda ko‘proq muhim bo‘lsa ham, image classificationda ham Global Average Pooling kabi operatsiyalar neck vazifasini bajaradi.

Global Average Pooling — feature mapni bitta vector ko‘rinishiga siqish usuli. Feature map — model ajratgan belgilar xaritasi. Vector — bitta yo‘nalishli raqamlar ro‘yxati.

Head

Head yakuniy prediction chiqaradigan qism. Head classlar bo‘yicha score yoki probability hosil qiladi.

Masalan, model cat vs dog vazifasini bajarsa, head quyidagi natijani chiqarishi mumkin:

Cat: 85%

Dog: 15%

Head modelning qaror chiqaruvchi qismi sifatida ishlaydi.

Korxona misolida bunday tasavvur qilish mumkin: backbone kerakli ma’lumotlarni yig‘adi, neck ularni tartibga soladi, head esa yakuniy qaror chiqaradi. Shu uch qism birga ishlaganda model rasmni tahlil qilib class prediction qiladi.

Input Layer

Input Layer — modelga kiruvchi birinchi qatlam. Image Classificationda input layer raw image data, ya’ni rasmning xom pixel

qiymatlarini qabul qiladi. Raw image data — hali model ichida qayta ishlanmagan rasm ma'lumoti.

Masalan, rasm 224x224x3 bo'lsa:

224 → rasm balandligi

224 → rasm kengligi

3 → RGB kanal soni

Input layer ko'zga o'xshatiladi. Ko'z tashqi dunyoni ko'radi, input layer esa rasm pixel qiymatlarini modelga qabul qiladi.

Input layer o'zi murakkab feature o'rganmaydi. U faqat ma'lumotni keyingi qatlamlarga uzatadi. Keyingi convolutional layerlar shu ma'lumotdan feature ajratishni boshlaydi.

Convolutional Layers — Backbone

Convolutional Layers CNN modelining asosiy qismi hisoblanadi. Convolutional Layer — rasm ustida filterlar yordamida yurib, featurelarni ajratadigan qatlam. Filter — kichik og'irliklar oynasi. Filter rasm ustida harakat qilib, muhim belgilarni topadi.

Feature — rasm ichidagi foydali belgi. Masalan:

qirra

chiziq

burchak

rang o'zgarishi

ko'z

quloq

g'ildirak

tumshuq

Convolutional Layers backbone tarkibiga kiradi. Backbone rasmning kerakli qismlarini ajratadi. Masalan, mushuk rasmini tanishda model mushukning qulog‘i, ko‘zi, yuz tuzilishi, mo‘ylovi kabi belgilarni ajratishi mumkin.

Filterlar yordamida rasmda turli belgilar aniqlanadi. Birinchi convolutional qatlam oddiy qirra va chiziqlarni topishi mumkin. Keyingi qatlamlar murakkabroq belgilarni, masalan, yuz yoki obyekt qismlarini aniqlaydi. Oxirgi qatlamlar esa butun obyektga yaqin featurelarni hosil qiladi.

Convolution jarayoni rasm ichidagi lokal hududlarga qaraydi. Lokal hudud — rasmning kichik qismi. Masalan, 3x3 filter rasmning 3x3 pixel maydonini tekshiradi. Shu sababli CNN rasm ichidagi joylashuv va shakl belgilarini yaxshi o‘rganadi.

Convolutional Layers ishlashini tushunish

Convolutional layer rasmni bir vaqtning o‘zida to‘liq oddiy jadval sifatida emas, kichik-kichik qismlar orqali o‘rganadi. Filter rasm ustida siljiydi va har bir joyda hisoblash bajaradi.

Masalan, 3x3 filter ishlatilsa, u rasmning 3x3 pixel maydonini oladi. Har bir pixel qiymati filterdagi weight bilan ko‘paytiriladi, keyin yig‘indi olinadi. Shu natija feature mapdagi bitta qiymatga aylanadi.

Feature map — filter topgan belgilar xaritasi. Agar filter qirralarni topishga o‘rgangan bo‘lsa, feature mapda qirralar kuchliroq ko‘rinadi. Agar filter rang o‘zgarishini topishga o‘rgangan bo‘lsa, rang keskin o‘zgaradigan joylarda qiymatlar yuqori bo‘ladi.

Convolutional layers yordamida model rasmni bosqichma-bosqich abstraktroq ko‘rinishda tushunadi. Abstrakt — umumlashtirilgan, aniq pixel emas, balki ma’no beruvchi belgi.

Mushuk tasviri misol sifatida olinganda, avval chiziqlar va qirralar topiladi. Keyin quloq, ko‘z, burun kabi qismlar ajraladi. Oxirida shu qismlar birlashib, model mushuk classini tanlashi mumkin.

Pooling Layers — Backbone

Pooling Layers CNNda rasm o‘lchamini kichraytirish va muhim ma’lumotlarni saqlab qolish uchun ishlatiladi. Pooling — ma’lumotni kichikroq ko‘rinishga keltirish. Bu qatlam feature map hajmini kamaytiradi.

Pooling layers backbone tarkibiga kiradi. U convolutional layerdan chiqqan feature mapni soddalashtiradi. Masalan, katta kitobdan umumiy xulosa olishga o‘xshaydi. Kitob juda katta bo‘lishi mumkin, lekin asosiy fikr qisqa xulosa bilan ifodalanadi. Pooling ham katta feature mapdan muhim qismlarni olib qoladi.

Poolingning ikki asosiy turi bor:

Max Pooling

Average Pooling

Max Pooling — eng kuchli feature qiymatini olib qoladi. Max — eng katta degani. Masalan, 2x2 maydonda qiymatlar 1, 3, 5, 2 bo‘lsa, Max Pooling 5 ni tanlaydi.

Average Pooling — qiymatlarning o‘rtachasini oladi. Average — o‘rtacha degani. Masalan, 2x2 maydonda qiymatlar 1, 3, 5, 2 bo‘lsa, average quyidagicha bo‘ladi:

$$(1 + 3 + 5 + 2) / 4 = 2.75$$

2x2 Pooling misolida feature map kichik bloklarga bo‘linadi. Har bir 2x2 blokdan bitta qiymat olinadi. Max Poolingda eng kattasi olinadi, Average Poolingda o‘rtacha olinadi. Natijada feature map kichrayadi.

Poolingning foydasi:

model tezroq ishlaydi
xotira kamroq ishlatiladi
muhim featurelar saqlanadi
kichik siljishlarga chidamlilik oshadi
overfitting kamayishi mumkin

Kichik siljishlarga chidamlilik deganda obyekt rasmda biroz chapga yoki o‘ngga siljisa ham, model uni taniy olishi tushuniladi.

Neck — Global Average Pooling

Neck backbone va head orasidagi qism hisoblanadi. Backbone featurelarni ajratadi, head esa yakuniy prediction qiladi. Neck shu ikki qism orasida ma’lumotlarni tartibga soladi.

Global Average Pooling neck ichidagi muhim operatsiyalardan biri. Global Average Pooling feature mapni bitta vector ko‘rinishiga aylantiradi.

Feature map shakli odatda quyidagicha bo‘ladi:

$$H \times W \times C$$

H — height, ya’ni balandlik.

W — width, ya’ni kenglik.

C — channel, ya’ni kanal soni.

Global Average Poolingdan keyin u quyidagiga aylanadi:

$$1 \times 1 \times C$$

Bu esa vector sifatida ishlatiladi. Masalan, $7 \times 7 \times 512$ feature map bo'lsa, Global Average Pooling har bir channel bo'yicha o'rtacha qiymat oladi va $1 \times 1 \times 512$ vector hosil qiladi.

Global Average Poolingning roli — featurelarni siqish. Compress features — featurelarni ixcham qilish degani. Bu fully connected layerga berishdan oldin ma'lumotni tartibliroq holatga keltiradi.

Neck tarkibida boshqa komponentlar ham bo'lishi mumkin:

FPN

Upsampling

Concatenation

FPN — Feature Pyramid Network. Multi-scale fusion uchun ishlatiladi. Multi-scale fusion — turli o'lchamdagi featurelarni birlashtirish. Object detectionda kichik va katta obyektlarni birga aniqlashda foydali.

Upsampling — resolutionni oshirish. Ya'ni kichik feature mapni kattaroq qilish. Segmentationda ko'p ishlatiladi.

Concatenation — featurelarni birlashtirish. Masalan, ikkita vector yoki feature mapni yonma-yon qo'shish.

Image Classificationda neck oddiyroq bo'lishi mumkin. Ko'pincha Global Average Pooling yetarli bo'ladi.

Fully Connected Layer — Head

Fully Connected Layer modelning head qismida ishlatiladi. Fully Connected — har bir kiruvchi qiymat har bir chiqish neuroniga ulangan qatlam. Dense layer ham shu ma'noda ishlatiladi. Dense — zich bog'langan degani.

Fully Connected Layer ajratilgan featurelar orasidagi munosabatlarni o'rganadi. Masalan, backbone mushukning qulog'i, ko'zi va mo'yloviga o'xshash featurelarni ajratgan bo'lsa, fully connected layer shu featurelar kombinatsiyasiga qarab yakuniy qaror chiqaradi.

Bu qatlam brain making final decision, ya'ni miya yakuniy qaror chiqarayotgandek ishlaydi. Masalan, cat vs dog classificationda fully connected layer ajratilgan featurelar asosida rasm mushukmi yoki itmi degan qarorga keladi.

Fully Connected Layer chiqishi classlar soniga bog'liq bo'ladi. Agar 2 ta class bo'lsa, output 2 ta qiymat bo'lishi mumkin. Agar 10 ta class bo'lsa, output 10 ta qiymat bo'ladi.

Masalan:

Cat score = 3.2

Dog score = 1.1

Bu qiymatlar hali ehtimollik emas. Ular class score hisoblanadi. Keyingi bosqichda Softmax bu scorelarni probabilityga aylantiradi.

Softmax Activation — Head

Softmax Activation modelning head qismida outputlarni ehtimolliklarga aylantirish uchun ishlatiladi. Softmax — class scorelarni probability, ya'ni ehtimollik ko'rinishiga o'tkazadigan funksiya.

Masalan, model quyidagicha natija chiqarsa:

Cat score = 3.2

Dog score = 1.1

Softmaxdan keyin natija quyidagicha bo'lishi mumkin:

Cat = 85%

Dog = 15%

Bu yerda model rasmni 85% ehtimol bilan cat deb hisoblaydi. Cat — mushuk. Dog — it.

Softmaxning asosiy xususiyati shundaki, barcha class probabilitylar yig'indisi 100% bo'ladi. Masalan:

Cat 85% + Dog 15% = 100%

Agar classlar ko'p bo'lsa, Softmax har bir classga alohida ehtimollik beradi. Eng katta probabilityga ega class yakuniy prediction sifatida olinadi.

Softmax Multi-Class Classificationda juda ko'p ishlatiladi. Multi-Class Classification — ko'p class ichidan faqat bittasini tanlash vazifasi. Masalan, model 10 ta classdan bittasini tanlaydi.

Binary Classificationda esa Sigmoid ham ishlatilishi mumkin. Sigmoid — qiymatni 0 va 1 oralig'iga keltiradigan activation function. Lekin 2 classli Softmax ham ishlatilishi mumkin.

CNN qismlarining umumiy bog'lanishi

CNN modelining asosiy qismlari quyidagicha ketma-ket ishlaydi:

Input Layer
↓
Convolutional Layers
↓
Pooling Layers
↓
Global Average Pooling
↓
Fully Connected Layer
↓
Softmax
↓
Prediction

Input Layer rasmni modelga qabul qiladi. Convolutional Layers rasm ichidan feature ajratadi. Pooling Layers feature mapni kichraytiradi va muhim belgilarni saqlaydi. Global Average Pooling featurelarni vector ko'rinishiga keltiradi. Fully Connected Layer featurelar asosida class score chiqaradi. Softmax scorelarni probabilityga aylantiradi. Prediction yakuniy classni bildiradi.

Masalan, cat vs dog vazifasida rasm modelga kiradi. Backbone mushuk yoki itga xos belgilarni ajratadi. Neck ma'lumotlarni ixchamlaydi. Head yakuniy qaror chiqaradi. Softmax natijani ehtimollik sifatida beradi.

Backbone, Neck, Head ma'nosi

CNN partlari inson tanasi orqali eslab qolish oson bo'ladi.

Backbone — umurtqa pog'onasi. Bu asosiy tayanch. Modelda backbone feature extractor hisoblanadi. Feature extractor — rasm ichidagi foydali belgilarni ajratadigan qism.

Neck — bo'yin. Bu bog'lovchi qism. Modelda neck backbone va head orasida featurelarni tartiblaydi, uzatadi yoki ixchamlaydi.

Head — bosh. Bu qaror qabul qiladigan qism. Modelda head yakuniy class prediction chiqaradi.

Jadval misol sifatida olinganda quyidagi mazmun kelib chiqadi:

Backbone → asosiy tayanch, feature extractor

Neck → bog'lovchi qism, ma'lumotni uzatadi

Head → qaror qabul qiladi

Bu tuzilma faqat image classificationda emas, object detection va segmentation modellarda ham ishlatiladi. Object detectionda head bounding box va class prediction chiqaradi. Segmentationda head pixel-level mask chiqaradi. Image Classificationda head class probability chiqaradi.

Yakuniy mazmun

Computer Vision modelini tushunishda Data Preparation va Model Architecture bir-biri bilan kuchli bog'langan. Data Preparation yaxshi bo'lmasa, model architecture kuchli bo'lsa ham natija yomon chiqishi mumkin. Rasm datasetlari toza, tartibli va ma'noli papkalarda bo'lishi kerak. Dataset size, file names, local folder path va class nomlari to'g'ri tekshirilishi kerak.

Tayyor datasetlar o'rganish uchun katta yordam beradi. CIFAR10 oddiy va tez experimentlar uchun qulay. CIFAR100 ko'proq class bilan qiyinroq vazifani beradi. MNIST yangi boshlovchilar uchun juda sodda. FashionMNIST kiyim classification orqali biroz realroq masala beradi. SVHN real sahnadagi raqamlarni tanishga yordam beradi. STL10, Flowers102, Food101, OxfordIIITPet va Caltech101 esa turli darajadagi Computer Vision projectlar uchun ishlatiladi.

Model Architecture neural networkning qanday ishlashini tushuntiradi. Input layer rasmni qabul qiladi. Convolutional layers rasm ichidan feature ajratadi. Pooling layers muhim ma'lumotlarni saqlab, hajmni kamaytiradi. Neck featurelarni tartiblaydi. Fully connected layer va Softmax yakuniy class prediction chiqaradi.

Neural Network o'rganish jarayonida forward pass, loss function, gradient descent, backpropagation, optimizer, learning rate, epoch, batch kabi tushunchalar birga ishlaydi. Model prediction qiladi, loss hisoblanadi, xato orqaga tarqatiladi, optimizer weightsni yangilaydi va model asta-sekin yaxshilanadi.

Backbone, Neck va Head modeli tushunish uchun juda qulay bo'lgan uchlik hisoblanadi. Backbone featurelarni ajratadi, Neck ularni tartiblaydi, Head esa yakuniy qaror chiqaradi. Image Classification modelida bu jarayon rasmni classga ajratish bilan yakunlanadi.

Computer Vision projectda nazariya va amaliyot birga yurishi kerak. Datasetni to'g'ri tayyorlash, architecture qismlarini tushunish, CNN qatlamlari qanday ishlashini bilish va prediction jarayonini anglash model yaratishdagi asosiy poydevor hisoblanadi.