

Savol-javob

1. Architecture nima?

Architecture — modelning ichki tuzilishi, qismlari va ma'lumot model ichida qanday harakatlanishini ko'rsatadigan umumiy sxema hisoblanadi. Architecture so'zini o'zbekchada “arxitektura”, “tuzilish” yoki “model qurilishi” deb tushunish mumkin.

Oddiy qilib aytganda, architecture modelning “skeleti” hisoblanadi. Model qanday input oladi, input qaysi qatlamlardan o'tadi, qaysi joyda feature ajratiladi, qaysi joyda qaror chiqariladi va output qanday hosil bo'ladi — bularning hammasi architecture ichiga kiradi.

Input — modelga kiruvchi ma'lumot. Computer Visionda input ko'pincha rasm bo'ladi. Masalan, $224 \times 224 \times 3$ o'lchamdagi rasm input bo'lishi mumkin. Bu yerda 224 rasm balandligi, 224 rasm kengligi, 3 esa rang kanallari soni. RGB rasmda 3 ta kanal bo'ladi: Red, Green, Blue. Red — qizil, Green — yashil, Blue — ko'k.

Output — modeldan chiqadigan yakuniy natija. Image Classificationda output class nomi yoki class ehtimolligi bo'ladi. Masalan:

Cat: 85%

Dog: 15%

Bu natijada model rasmni 85 foiz ehtimol bilan mushuk deb hisoblaydi.

Model architecture odatda quyidagi savollarga javob beradi:

1. Model qanday ma'lumot qabul qiladi?
2. Model ichida nechta qatlam bor?
3. Har bir qatlam nima vazifa bajaradi?
4. Feature qayerda ajratiladi?
5. Qaror qaysi qatlamda chiqariladi?
6. Output qanday ko'rinishda chiqadi?

Neural Network architecture — neural networkning qatlamlari va ular orasidagi bog'lanishlar tuzilishi. Neural Network — neyron tarmoq, ya'ni ma'lumotlardan pattern o'rganadigan model. Pattern — takrorlanadigan belgi yoki qonuniyat.

Image Classification uchun model architecture odatda quyidagicha bo'ladi:

Input Image

↓

Convolutional Layers

↓

Pooling Layers

↓

Global Average Pooling yoki Flatten

↓

Fully Connected Layer

↓

Softmax

↓

Prediction

Convolutional Layer — rasm ichidagi belgilarni ajratadigan qatlam. Bu qatlam filterlar yordamida rasm ustida yurib, qirra, chiziq, rang

o'zgarishi, shakl kabi featurelarni topadi. Feature — rasm ichidagi muhim belgi yoki xususiyat.

Pooling Layer — feature map hajmini kichraytiradigan qatlam.

Feature map — model ajratgan belgilar xaritasi. Pooling muhim ma'lumotlarni saqlagan holda ortiqcha hajmni kamaytiradi.

Global Average Pooling — har bir kanal bo'yicha o'rtacha qiymat olib, feature mapni bitta vector ko'rinishiga keltiradi. Vector — raqamlar ro'yxati.

Flatten — ko'p o'lchamli ma'lumotni bitta uzun vector ko'rinishiga aylantirish.

Fully Connected Layer — yakuniy qaror chiqarishda ishlatiladigan zich bog'langan qatlam. Dense layer ham shu ma'noda ishlatiladi. Dense — zich bog'langan degani.

Softmax — output qiymatlarini ehtimolliklarga aylantiradigan activation function. Activation function — modelga murakkab munosabatlarni o'rganishga yordam beradigan funksiya.

Prediction — modelning taxmini yoki yakuniy javobi.

CNN architecture uchta katta qismga ham bo'linadi:

Backbone

Neck

Head

Backbone — asosiy tayanch qism. Rasm ichidan feature ajratadi.

Backbone so'zining oddiy ma'nosi “umurtqa pog'onasi” yoki “asosiy tayanch” degani. CNN, ResNet, EfficientNet kabi modellar backbone bo'lishi mumkin.

Neck — backbone va head orasidagi bog‘lovchi qism. Neck featurelarni tartiblaydi, ixchamlaydi yoki kerakli formatga keltiradi. Neck so‘zining oddiy ma’nosi “bo‘yin”.

Head — yakuniy qaror chiqaradigan qism. Head class score yoki probability chiqaradi. Head so‘zining oddiy ma’nosi “bosh”. Modelda head qaror qabul qiluvchi qism hisoblanadi.

Architecture inson ko‘rishi bilan taqqoslanganda bunday tushuniladi:

Inson:

Ko‘z → Miya → Qaror

CNN:

Image → Layers → Prediction

Ko‘z rasmni ko‘radi. Miya rasmni tahlil qiladi. Oxirida inson qaror chiqaradi. CNN modelida input image rasm sifatida kiradi, layers rasmni qayta ishlaydi, prediction esa yakuniy classni chiqaradi.

Architecture yaxshi qurilsa, model ma’lumotdan to‘g‘ri feature ajratadi va yaxshi prediction qiladi. Architecture noto‘g‘ri yoki juda sodda bo‘lsa, model murakkab belgilarni o‘rgana olmasligi mumkin. Juda katta architecture ishlatilsa, model ko‘p xotira va GPU talab qilishi, overfitting qilishi yoki sekin ishlashi mumkin.

Overfitting — model training data’ni yodlab olib, yangi data’da yomon ishlashi. Training data — model o‘rganadigan ma’lumot. Yangi data — model oldin ko‘rmagan ma’lumot.

Architecture tanlashda quyidagilar hisobga olinadi:

dataset hajmi

classlar soni

rasm o‘lchami

model productda qayerda ishlashi
GPU yoki CPU imkoniyati
tezlik talabi
aniqlik talabi

Masalan, telefon yoki edge device uchun juda katta model emas, MobileNet kabi yengil model ishlatilishi mumkin. Edge device — kichik qurilma, masalan telefon, kamera yoki Raspberry Pi. Katta server va kuchli GPU bo'lsa, ResNet yoki EfficientNet kabi kattaroq model ishlatilishi mumkin.

Architecture modelning umumiy rejasi bo'lgani uchun u model qurishdagi eng muhim tushunchalardan biri hisoblanadi.

2. Supervised ML tabular dataset bilan qo'lda model architecture chizish

Supervised ML — nazoratli mashinali o'rganish degani. Supervised so'zi “nazoratli” degani. Bunday o'rganishda dataset ichida input ma'lumotlar va to'g'ri javoblar bo'ladi. To'g'ri javob label deb ataladi.

Tabular dataset — jadval ko'rinishidagi dataset. Bunday dataset Excel yoki CSV faylga o'xshaydi. Unda qatorlar va ustunlar bo'ladi. Har bir qator bitta obyekt yoki bitta sample hisoblanadi. Har bir ustun esa feature bo'ladi.

Feature — model o'rganadigan belgi yoki xususiyat. Masalan, odamning yoshi, maoshi, ish tajribasi, qarz miqdori, xaridlar soni feature bo'lishi mumkin.

Label — model topishi kerak bo‘lgan to‘g‘ri javob. Masalan, kredit beriladimi yoki yo‘qmi, mijoz ketadimi yoki qoladimi, kasallik bormi yoki yo‘qmi.

Supervised ML uchun oddiy misol:

Vazifa: mijoz kreditni qaytara oladimi yoki yo‘qmi?

Input features:

- age
- salary
- job_years
- debt
- credit_score

Label:

- approved yoki rejected

Age — yosh.

Salary — maosh.

Job_years — ish tajribasi yillari.

Debt — qarz.

Credit_score — kredit reytingi.

Approved — tasdiqlandi.

Rejected — rad qilindi.

Bunday tabular dataset uchun model architecture qo‘lda quyidagicha chiziladi:

Raw Tabular Data
↓
Data Cleaning
↓
Feature Engineering
↓
Encoding
↓
Scaling
↓
Train / Validation / Test Split
↓
ML Model
↓
Prediction
↓
Evaluation
↓
Deployment

1. Raw Tabular Data

Raw Tabular Data — hali tozalanmagan jadval ma'lumot. Raw — xom, boshlang'ich holatdagi ma'lumot.

Masalan:

age	salary	city	job_years	debt	label
25	3000	Seoul	2	1000	approved
41	4500	Busan	8	5000	rejected

Bu ma'lumotlarda sonli ustunlar ham, matnli ustunlar ham bo'lishi mumkin.

Sonli ustunlar:

age
salary
job_years
debt

Matnli ustunlar:

city
label

2. Data Cleaning

Data Cleaning — ma'lumotni tozalash. Bu bosqichda noto'g'ri, bo'sh, takroriy yoki g'alati qiymatlar tuzatiladi.

Data Cleaning ichiga quyidagilar kiradi:

missing values bilan ishlash
duplicate rows olib tashlash
outlier tekshirish
noto'g'ri formatlarni tuzatish
ustun nomlarini tartibga keltirish

Missing values — bo'sh qiymatlar. Masalan, salary ustunida ayrim joylar bo'sh bo'lishi mumkin.

Duplicate rows — takrorlangan qatorlar.

Outlier — juda gʻalati yoki chetda turgan qiymat. Masalan, age ustunida 250 chiqib qolsa, bu outlier boʻlishi mumkin.

3. Feature Engineering

Feature Engineering — yangi foydali featurelar yaratish. Bu bosqichda mavjud ustunlardan model uchun kuchliroq maʼlumotlar olinadi.

Masalan:

```
salary_per_debt = salary / debt  
experience_group = job_years bo'yicha guruh  
age_group = yosh bo'yicha guruh
```

Feature Engineering modelga yaxshiroq pattern topishga yordam beradi.

4. Encoding

Encoding — matnli qiymatlarni raqamga aylantirish. ML model koʻpincha sonlar bilan ishlaydi. Shuning uchun `city`, `gender`, `category` kabi ustunlar raqamga oʻtkaziladi.

Encoding turlari:

Label Encoding

One-Hot Encoding

Ordinal Encoding

Frequency Encoding

Label Encoding — har bir kategoriya raqam bilan almashtiriladi.

Masalan:

Seoul → 0

Busan → 1

Daegu → 2

One-Hot Encoding — har bir kategoriya alohida ustunga aylantiriladi.

Masalan:

city_Seoul

city_Busan

city_Daegu

Ordinal Encoding — tartibli kategoriyalarni raqamga aylantirish.

Masalan:

low → 0

medium → 1

high → 2

Frequency Encoding — kategoriya necha marta uchrashiga qarab raqam berish.

5. Scaling

Scaling — sonli ustunlarni bir xil o'lchovga keltirish. Masalan, salary 3000 bo'lishi, age esa 25 bo'lishi mumkin. Katta qiymatli ustun modelga haddan tashqari ta'sir qilmasligi uchun scaling ishlatiladi.

Scaling turlari:

StandardScaler

MinMaxScaler

RobustScaler

StandardScaler — qiymatlarni oʻrtacha 0, standart ogʻish 1 atrofida qiladi.

MinMaxScaler — qiymatlarni 0 va 1 oraligʻiga keltiradi.

RobustScaler — outlierlarga chidamli scaling usuli.

Scaling ayniqsa Logistic Regression, SVM, KNN, Neural Network kabi modellarda muhim. Decision Tree, Random Forest, XGBoost kabi tree-based modellar scalingga kamroq muhtoj boʻladi.

Tree-based model — qaror daraxtlariga asoslangan model.

6. Train / Validation / Test Split

Dataset uch qismga ajratiladi:

Train

Validation

Test

Train — model oʻrganadigan qism.

Validation — model sozlamalarini tekshirish uchun ishlatiladigan qism.

Test — yakuniy baholash uchun ishlatiladigan qism.

Masalan:

70% train

15% validation

15% test

Test dataset model trainingda ishlatilmaydi. Bu model yangi maʼlumotda qanday ishlashini adolatli baholash uchun kerak.

7. ML Model

Tabular dataset uchun turli supervised ML modellardan foydalaniladi:

Logistic Regression

Decision Tree

Random Forest

XGBoost

LightGBM

CatBoost

SVM

KNN

Logistic Regression — binary classificationda ko‘p ishlatiladigan oddiy model.

Decision Tree — qaror daraxti.

Random Forest — ko‘plab decision tree’lardan iborat ensemble model. Ensemble — bir nechta modelni birlashtirish usuli.

XGBoost, LightGBM, CatBoost — gradient boosting asosidagi kuchli modellar. Gradient boosting — xatolarni ketma-ket tuzatib boradigan model qurish usuli.

SVM — Support Vector Machine. Classlar orasidagi eng yaxshi chegarani topishga harakat qiladi.

KNN — K-Nearest Neighbors. Yangi sample qaysi classga tegishli ekanini eng yaqin qo‘shnilar orqali aniqlaydi.

8. Prediction

Prediction — modelning taxmini. Masalan, model mijozni approved yoki rejected deb aytadi.

Masalan:

Input:

age = 30

salary = 4000

job_years = 5

debt = 1000

Output:

approved

Model input featurelarga qarab output chiqaradi.

9. Evaluation

Evaluation — model natijasini baholash. Classification vazifasida quyidagi metriclar ishlatiladi:

Accuracy

Precision

Recall

F1-score

ROC-AUC

Confusion Matrix

Accuracy — umumiy to‘g‘ri javoblar ulushi.

Precision — model bir class deb aytganlar ichida nechta to‘g‘ri ekanini bildiradi.

Recall — haqiqiy classdagi obyektlardan nechta topilganini bildiradi.

F1-score — precision va recall o‘rtasidagi muvozanat.

ROC-AUC — binary classificationda model classlarni ajratish qobiliyatini o‘lchaydi.

Confusion Matrix — model qaysi classni qaysi class bilan adashtirganini ko‘rsatadigan jadval.

10. Deployment

Deployment — modelni real ishlaydigan tizimga chiqarish. Masalan, model API qilib serverga joylanadi. API — Application Programming Interface, ya’ni boshqa dasturlar modelga so‘rov yuborishi va javob olishi uchun interfeys.

Tabular ML model product flow quyidagicha bo‘ladi:

User input

↓

API

↓

Preprocessing

↓

Model prediction

↓

Response


Response — tizim qaytargan javob.

Masalan:

```
{  
  "prediction": "approved",  
  "confidence": 0.87  
}
```

Confidence — modelning ishonch darajasi.

Supervised ML architecture qo'lda chizma ko'rinishida





Train / Val / Test
Split



ML Model
LR / RF / XGBoost



Prediction
class / probability



Evaluation
Acc / F1 / ROC-AUC



Deployment
API / App / Product

Bu architecture Supervised ML modelini boshidan productgacha olib boradigan umumiy sxema hisoblanadi. Tabular datasetda rasm emas, jadval ustunlari bilan ishlanadi. Lekin umumiy pipeline Computer Visionga o‘xshaydi: data tayyorlanadi, model train qilinadi, baholanadi va productga chiqariladi.

3. Image Classificationni qayerlarda ko‘rish mumkin? Real ishlayotgan mashhur loyihalar

Image Classification bugungi kunda ko‘plab real tizimlarda ishlatiladi. Image Classification — rasmni classga ajratish. Model rasmni ko‘rib, unda nima borligini aniqlaydi yoki rasmga mos label beradi.

Image Classification alohida product sifatida ham, katta Computer Vision tizimining bir qismi sifatida ham ishlatiladi. Masalan, rasm ichidagi obyektни tanish, rasmga tag qo‘yish, zararli kontentni aniqlash, tibbiy tasvirni baholash, mahsulot turini aniqlash kabi vazifalarda ishlatiladi.

1. Google Lens

Google Lens real hayotda ishlayotgan mashhur Computer Vision productlardan biri hisoblanadi. Google Lens kamera yoki rasm orqali obyektlarni tushunishga yordam beradi. Masalan, o‘simlik, hayvon, mahsulot, joy, matn yoki QR kodni kamera orqali tanish mumkin.

Google Lens ichida faqat image classification emas, balki OCR, object detection va image search ham ishlashi mumkin. OCR — rasmdagi matnni o‘qish. Image search — rasm orqali qidirish. Lekin image classification ham muhim qism hisoblanadi, chunki tizim rasmda qanday obyekt yoki kategoriya borligini tushunishi kerak.

Masalan:

Input: gul rasmi

Output: plant / flower category

Plant — o'simlik. Flower — gul.

Yana bir misol:

Input: it rasmi

Output: dog breed yoki similar images

Breed — zot. Similar images — o'xshash rasmlar.

Google Lens kundalik hayotda rasmni tushunish, narsalarni qidirish, matnni tarjima qilish, mahsulotni topish kabi vazifalarda ishlatiladi.

2. Google Photos

Google Photos rasmlarni avtomatik tartiblash va qidirish uchun Computer Visiondan foydalanadigan mashhur product hisoblanadi. Google Photos ichida odamlar, hayvonlar, joylar va narsalar bo'yicha qidirish mumkin.

Masalan, foydalanuvchi “dog”, “beach”, “car”, “food” kabi so'zlarni qidirsang, Google Photos rasmlar orasidan moslarini topishga harakat qiladi.

Dog — it. Beach — plyaj. Car — mashina. Food — ovqat.

Bu yerda image classification va image tagging ishlaydi. Image tagging — rasmga avtomatik label yoki tag qo'yish. Tag — rasm mazmunini bildiruvchi kalit so'z.

Masalan:

Rasmda it bo'lsa → dog tag
Rasmda ovqat bo'lsa → food tag
Rasmda dengiz bo'lsa → beach tag

Google Photosda face grouping ham bor. Face grouping — yuzlarni guruhlash. Face — yuz. Bunda bir xil odam yoki uy hayvonlari rasmlari alohida guruhlanishi mumkin.

Bu product Image Classificationning real hayotdagi juda tushunarli misoli hisoblanadi, chunki foydalanuvchi rasmlar ichidan qidirganda model rasm mazmunini oldindan tahlil qilgan bo'ladi.

3. Apple Photos Visual Look Up

Apple ekosistimida Visual Look Up funksiyasi rasm va videolardagi obyektlarni aniqlashga yordam beradi. Visual Look Up — “ko‘rib tanish va ma’lumot topish” degan ma’noga yaqin. Bu funksiya rasmda ko‘rinayotgan obyekt haqida ma’lumot olishga yordam beradi.

Masalan, rasmda quyidagilar bo'lsa, tizim ularni tanishi mumkin:

o'simlik
hayvon
mashhur joy
san'at asari
kitob
haykal

Bu yerda Image Classification model rasmda qaysi obyekt turi borligini aniqlaydi. Agar rasmda o'simlik bo'lsa, u o'simlik sifatida taniladi. Agar rasmda mashhur bino bo'lsa, landmark sifatida tanilishi mumkin.

Landmark — mashhur joy yoki tarixiy bino.

Visual Look Up kundalik hayotdagi image classificationga yaxshi misol bo‘ladi, chunki telefon rasmlar ichidagi obyektlarni tushunishga harakat qiladi.

4. Azure AI Vision

Azure AI Vision Microsoftning rasmni tahlil qilish xizmatlaridan biri hisoblanadi. Bu xizmat rasm ichidagi visual featurelarni tahlil qiladi. Visual feature — rasm ichidagi ko‘rinadigan belgi yoki xususiyat. Masalan, obyektlar, odamlar, matn, taglar yoki captionlar.

Caption — rasmga matnli izoh. Masalan, “a dog sitting on grass” — “maysa ustida o‘tirgan it” degani.

Azure AI Vision image analysis, OCR, object detection, image tagging kabi vazifalarda ishlatilishi mumkin. Bu cloud service sifatida ishlaydi. Cloud service — internetdagi serverlar orqali ishlaydigan xizmat.

Masalan, kompaniya o‘z ilovasiga rasm yuklash funksiyasi qo‘shadi. Rasm Azure AI Visionga yuboriladi. Xizmat rasm ichidagi obyektlar, taglar yoki matnni aniqlaydi. Keyin natija ilovaga qaytadi.

5. Tibbiy image classification loyihalari

Tibbiyotda Image Classification juda muhim yo‘nalishlardan biri hisoblanadi. Medical AI — tibbiy sun’iy intellekt. Bunda model rentgen, MRT, CT, ultratovush yoki teri rasmi kabi tasvirlarni tahlil qiladi.

Masalan:

X-ray → pneumonia yoki normal

Skin image → melanoma yoki benign

Eye scan → diabetic retinopathy bor yoki yo‘q

X-ray — rentgen tasviri.

Pneumonia — o‘pka yallig‘lanishi.

Normal — sog‘lom holat.

Melanoma — xavfli teri saratoni turi.

Benign — xavfsiz, yomon sifatli bo‘lmagan.

Diabetic retinopathy — diabet sababli ko‘z to‘r pardasi zararlanishi.

Bunday tizimlarda model shifokorga yordamchi vosita sifatida ishlaydi. Model tasvirlarni tez tahlil qiladi va xavfli holatlarga e‘tibor qaratadi. Yakuniy tashxisni shifokor qo‘yadi.

6. E-commerce product classification

E-commerce — internet savdo sohasi. Online do‘konlarda millionlab mahsulot rasmlari bo‘ladi. Image Classification mahsulotlarni avtomatik kategoriya qilishda ishlatiladi.

Masalan:

rasm → shoes

rasm → shirt

rasm → bag

rasm → phone

Shoes — poyabzal.

Shirt — ko‘ylak.

Bag — sumka.

Phone — telefon.

Bu tizim sotuvchiga mahsulot yuklashni osonlashtiradi. Foydalanuvchi rasm yuklaganda, model mahsulot kategoriyasini avtomatik tanlashi mumkin. Shuningdek, qidiruv va tavsiya tizimlarida ham rasm classification yordam beradi.

Recommendation system — tavsiya tizimi. Masalan, foydalanuvchiga o'xshash mahsulotlarni ko'rsatish.

7. Social media image tagging

Social media platformalarda Image Classification va Multi-Label Classification ko'p ishlatiladi. Social media — ijtimoiy tarmoqlar. Image tagging — rasimga teg qo'yish.

Masalan, rasmda quyidagilar bo'lsa:

person
car
tree
beach
food
dog

Model rasimga mos taglar beradi. Bu qidiruv, filterlash, tavsiya, xavfsizlik va kontent boshqarish uchun foydali.

Content moderation — zararli yoki taqiqlangan kontentni aniqlash. Masalan, zo'ravonlik, yalang'ochlik, xavfli belgilar yoki spam rasmlarni aniqlash.

8. Manufacturing defect classification

Manufacturing — ishlab chiqarish sohasi. Defect classification — nuqsonni aniqlash va tasniflash. Zavodlarda mahsulot rasmi olinadi va model mahsulot yaxshi yoki nuqsonli ekanini aniqlaydi.

Masalan:

good
scratched
broken
cracked
wrong shape

Good — yaxshi mahsulot.

Scratched — tiralgan.

Broken — singan.

Cracked — yoriq tushgan.

Wrong shape — noto‘g‘ri shakl.

Bu tizim quality control uchun ishlatiladi. Quality control — sifat nazorati. Kamera konveyerda harakatlanayotgan mahsulotni rasmga oladi, model esa nuqson bor yoki yo‘qligini aniqlaydi.

9. Agriculture image classification

Agriculture — qishloq xo‘jaligi. Image Classification o‘simlik kasalliklarini aniqlashda ishlatiladi.

Masalan:

healthy leaf
rust disease

leaf spot
powdery mildew

Healthy leaf — sog‘lom barg.

Rust disease — zamburug‘ kasalligi turi.

Leaf spot — bargdagi dog‘ kasalligi.

Powdery mildew — unshudring kasalligi.

Fermer barg rasmini yuklaydi. Model bargdagi dog‘, rang o‘zgarishi, qurish belgilari yoki kasallik ko‘rinishiga qarab classni aniqlaydi. Bu kasallikni erta aniqlashga yordam beradi.

10. Security va surveillance tizimlari

Security — xavfsizlik. Surveillance — kuzatuv. Image Classification xavfsizlik tizimlarida ham ishlatiladi.

Masalan:

mask vs no mask
helmet vs no helmet
uniform vs no uniform
weapon vs no weapon
normal vs suspicious

Helmet — kaska.

Uniform — maxsus kiyim.

Weapon — qurol.

Suspicious — shubhali.

Bu tizimlar zavod, maktab, aeroport, kasalxona, ombor va jamoat joylarida ishlatilishi mumkin. Kamera tasviridan model muhim holatni aniqlaydi va signal berishi mumkin.

Image Classification real hayotda juda ko‘p joyda ishlatiladi. Eng mashhur misollar telefon ilovalari, rasm qidiruv tizimlari, tibbiy AI, e-commerce, social media, ishlab chiqarish, qishloq xo‘jaligi va xavfsizlik tizimlari hisoblanadi.

4. Computer Vision model qilishdagi qiyinchiliklar

Computer Vision model yaratish oddiy ko‘rinishi mumkin, lekin real projectlarda juda ko‘p qiyinchiliklar bor. Darslarda odatda data, labeling, compute, overfitting, lighting va noise kabi asosiy muammolar ko‘riladi. Bundan tashqari ham amaliyotda uchraydigan ko‘plab muammolar mavjud.

1. Dataset sifati past bo‘lishi

Model sifati dataset sifatiga juda bog‘liq. Agar dataset ichida xira, noto‘g‘ri, buzilgan yoki noto‘g‘ri classga tushgan rasmlar bo‘lsa, model ham noto‘g‘ri o‘rganadi.

Masalan, cat papkasida it rasmi bo‘lsa, model chalkashadi. Chunki u it rasmini cat label bilan o‘rganadi. Bunday noto‘g‘ri label model uchun juda zararli.

Bad data — yomon sifatli ma’lumot. Computer Visionda bad data quyidagicha bo‘lishi mumkin:

- xira rasm
- noto‘g‘ri label
- buzilgan fayl
- juda kichik obyekt

ortiqcha fon
takroriy rasmlar
noto'g'ri class papkasi

2. Data leakage

Data leakage — test yoki validation ma'lumot trainingga aralashib ketishi. Bu juda xavfli muammo. Model natijasi sun'iy ravishda yuqori ko'rinadi, lekin real hayotda yomon ishlaydi.

Masalan, bir xil rasm train va test papkaga tushib qolsa, model testda yaxshi natija beradi. Chunki u rasmni oldin ko'rgan bo'ladi. Bu adolatli baholash emas.

Video datasetda ham leakage bo'lishi mumkin. Masalan, bitta videodan olingan juda o'xshash framelar train va testga tushib qolsa, test natija haddan tashqari yaxshi ko'rinadi. Lekin yangi videoda model yomon ishlashi mumkin.

3. Class imbalance

Class imbalance — classlar soni teng bo'lmasligi. Masalan:

cat: 5000 ta rasm
dog: 200 ta rasm

Bunday datasetda model ko'proq cat classini o'rganib oladi. Dog rasmlari kam bo'lgani uchun dog classida xato ko'p bo'lishi mumkin.

Class imbalance yechimlari:

kam classga ko'proq data yig'ish
data augmentation qilish
class weight ishlatish

oversampling
undersampling

Class weight — kam classga ko‘proq og‘irlik berish.

Oversampling — kam classdagi rasmlarni ko‘paytirib ishlatish.

Undersampling — ko‘p classdagi rasmlarni kamaytirish.

4. Domain shift

Domain shift — training data bilan real hayotdagi data o‘rtasida farq bo‘lishi. Masalan, model internetdan olingan chiroyli va toza rasmlarda train qilingan, lekin real hayotda kamera xira, qorong‘i va harakatlangan tasvir beradi.

Domain shift misollari:

training rasmlar studiyada olingan, real rasmlar ko‘chada olingan

training rasmlar yorug‘, real rasmlar qorong‘i

training rasmlar yuqori sifatli, real rasmlar xira

training rasmlar old tomondan, real rasmlar yon tomondan

Domain shift bo‘lsa, model real productda yomon ishlashi mumkin. Shu sababli dataset real sharoitga yaqin bo‘lishi kerak.

5. Annotation xatolari

Annotation — ma’lumotni belgilash. Image Classificationda annotation label berish bo‘lsa, Object Detectionda bounding box chizish, Segmentationda mask chizish bo‘ladi.

Annotation xatolari modelni noto'g'ri o'rgatadi. Masalan, object detectionda box obyektни to'liq qamrab olmasa yoki noto'g'ri obyektga chizilsa, model obyekt joyini noto'g'ri o'rganadi.

Bounding box — obyekt atrofida to'rtburchak ramka.

Mask — segmentationda obyektни pixel darajasida ajratish xaritasi.

6. Kichik dataset bilan katta model ishlatish

Agar dataset kichik, model esa juda katta bo'lsa, overfitting yuz berishi mumkin. Katta model juda ko'p parametrga ega bo'ladi va kichik datasetни yodlab olishi mumkin.

Parameter — model ichidagi o'rganiladigan qiymat. Weight va bias parametr hisoblanadi.

Bunday holatda yechimlar:

- pretrained modeldan foydalanish
- data augmentation qilish
- modelni kichraytirish
- dropout qo'shish
- early stopping ishlatish

Pretrained model — oldin katta datasetda o'qitilgan tayyor model.

Dropout — ayrim neuronlarni training vaqtida vaqtincha o'chirib, overfittingni kamaytirish usuli.

Early stopping — validation natija yomonlashganda trainingni to'xtatish.

7. Model interpretability muammosi

Interpretability — model qarorini tushuntira olish. Deep Learning modellar ko‘pincha “black box” bo‘ladi. Black box — ichida qanday qaror qilayotgani to‘liq ko‘rinmaydigan tizim.

Masalan, model rasmni “kasallik bor” deb topadi. Lekin nima uchun bunday qaror chiqarganini tushuntirish qiyin bo‘lishi mumkin. Tibbiyot, xavfsizlik va moliya kabi sohalarda bu muhim.

Yordamchi usullar:

Grad-CAM

Saliency map

SHAP

LIME

Grad-CAM — model rasmning qaysi joylariga e’tibor berganini issiqlik xaritasi orqali ko‘rsatadigan usul.

Saliency map — muhim pixel yoki hududlarni ko‘rsatadigan xarita.

SHAP va LIME — model qarorini tushuntirishga yordam beradigan interpretability usullari.

8. Inference tezligi

Inference — train qilingan modeldan yangi rasmda prediction olish jarayoni. Real productda model tez ishlashi kerak. Masalan, kamera real vaqtda video tahlil qilsa, model kechikmasligi kerak.

Latency — bitta so‘rovga javob berish vaqti. Masalan, rasm yuklangandan keyin model 0.2 soniyada javob bersa, latency past bo‘ladi. Agar 5 soniya kutish kerak bo‘lsa, latency yuqori bo‘ladi.

FPS — frames per second, ya'ni bir soniyada qayta ishlanadigan frame soni. Video tizimlarda FPS muhim.

Yechimlar:

- modelni kichraytirish
- quantization
- ONNX formatga o'tkazish
- TensorRT ishlatish
- batch inference
- GPUdan foydalanish

Quantization — model qiymatlarini kichikroq formatga o'tkazish. Masalan, float32 o'rniga int8.

ONNX — modelni turli frameworklarda ishlatish uchun format.

TensorRT — NVIDIA GPUlarda modelni tezlashtirish vositasi.

9. Deployment muammolari

Model local kompyuterda yaxshi ishlashi mumkin, lekin serverda yoki product muhitida xatolar chiqishi mumkin. Bu deployment muammosi hisoblanadi.

Deployment — modelni real ishlaydigan tizimga joylashtirish.

Muammolar:

- kutubxona versiyalari mos kelmasligi
- GPU driver muammosi
- model fayli topilmasligi
- path xatolari
- server xotirasi yetmasligi
- API sekin ishlashi

katta rasm fayllari tizimni sekinlashtirishi

Yechim sifatida Docker ishlatilishi mumkin. Docker — projectni bir xil environmentda ishga tushirish uchun container texnologiyasi. Container — kod, kutubxonalar va sozlamalar birga joylashgan paket.

10. Real-time video bilan ishlash qiyinligi

Video bilan ishlash rasmga qaraganda qiyinroq. Chunki video ko‘p framedan iborat. Har bir frame alohida rasm kabi ishlovdan o‘tadi. Bu ko‘p xotira va hisoblash quvvati talab qiladi.

Real-time — real vaqt rejimi. Masalan, kamera hozirgi paytda olayotgan videoni darhol tahlil qilish.

Video CV muammolari:

frame juda ko‘p bo‘ladi
harakat tez bo‘lishi mumkin
motion blur paydo bo‘ladi
kamera silkinadi
obyekt vaqtincha yo‘qoladi
model FPSni ushlab turishi kerak

Motion blur — harakat sababli rasmning xiralashishi.

11. Obyekt occlusion bo‘lishi

Occlusion — obyektning boshqa narsa bilan yopilib qolishi. Masalan, odamning yarmi mashina orqasida qolsa yoki hayvon daraxt ortida bo‘lsa, model uni tanishda qiynaladi.

Occlusion real hayotda ko‘p uchraydi. Object Detection va Pose Estimation vazifalarida bu ayniqsa qiyin.

12. Rasm resolution farqi

Resolution — rasm o‘lchami yoki aniqligi. Trainingda yuqori sifatli rasmlar ishlatilgan, real hayotda past sifatli rasmlar kelgan bo‘lsa, model xato qilishi mumkin.

Past resolutionda mayda featurelar yo‘qoladi. Masalan, hayvon ko‘zi, qulog‘i yoki mahsulotdagi kichik nuqson ko‘rinmasligi mumkin.

13. Model bias

Bias — modelning ayrim class, guruh yoki holatlarga nohaq moyilligi. Agar dataset bir tomonlama bo‘lsa, model ham bir tomonlama o‘rganadi.

Masalan, face recognition datasetida ayrim yosh, jins yoki millat rasmlari kam bo‘lsa, model o‘sha guruhlarda yomonroq ishlashi mumkin.

Face recognition — yuzni tanish.

Bias real productlarda jiddiy muammo hisoblanadi. Buni kamaytirish uchun dataset xilma-xil va adolatli yig‘ilishi kerak.

14. Privacy va security muammolari

Computer Vision ko‘pincha odam rasmi, yuz, kamera tasviri, tibbiy rasm kabi sezgir ma’lumotlar bilan ishlaydi. Privacy — shaxsiy ma’lumotlar maxfiyligi.

Masalan, xavfsizlik kamerasidagi odamlar rozilgisiz tahlil qilinsa, privacy muammosi paydo bo‘lishi mumkin. Tibbiy rasmlar esa bemor shaxsiy ma’lumotlari hisoblanadi.

Security — tizim xavfsizligi. Modelga noto‘g‘ri yoki zararli rasm yuborish orqali tizimni aldash mumkin. Bu adversarial attack deb

ataladi. Adversarial attack — modelni aldash uchun maxsus o'zgartirilgan input.

15. Model monitoring qiyinligi

Productga chiqqan modelni doim kuzatish kerak. Model vaqt o'tishi bilan yomon ishlay boshlashi mumkin. Chunki real data o'zgaradi.

Data drift — real hayotdagi ma'lumot training data'dan farq qilib ketishi.

Masalan, model eski kamera rasmlarida train qilingan, keyin yangi kamera ishlatila boshlagan. Rasm sifati, ranglar va burchak o'zgargan. Model accuracy pasayishi mumkin.

Monitoring orqali quyidagilar kuzatiladi:

accuracy pasayishi
latency oshishi
xato predictionlar
foydalanuvchi feedbacklari
server xatolari
data drift

Feedback — foydalanuvchi qaytargan fikr. Masalan, model noto'g'ri javob berganini foydalanuvchi belgilashi mumkin.

16. Real productda edge case muammolari

Edge case — kam uchraydigan, lekin muhim holat. Model trainingda bunday holatlarni ko'rmagan bo'lishi mumkin.

Masalan:

mushuk juda qorong'i joyda
mashina faqat yarmi ko'rinadi

yoʻl belgisi yomgʻirda xira
mahsulot teskari turgan
odam noodatliy holatda

Edge case real productlarda koʻp muammo chiqaradi. Buning uchun dataset kengaytiriladi, testlar koʻpaytiriladi va monitoring qilinadi.

Computer Vision model qilishdagi qoʻshimcha qiyinchiliklar umumiy roʻyxati

1. Dataset sifati past boʻlishi
2. Data leakage
3. Class imbalance
4. Domain shift
5. Annotation xatolari
6. Kichik dataset bilan katta model ishlatish
7. Model interpretability muammosi
8. Inference tezligi
9. Deployment muammolari
10. Real-time video bilan ishlash qiyinligi
11. Occlusion
12. Resolution farqi
13. Model bias
14. Privacy va security muammolari
15. Monitoring qiyinligi
16. Edge case muammolari

Computer Vision model qilishda faqat model architecture yaxshi boʻlishi yetarli emas. Dataset, label sifati, preprocessing, real sharoit, tezlik, deployment, monitoring va privacy kabi jihatlar ham bir xil darajada muhim hisoblanadi. Real projectlarda modelning yaxshi ishlashi butun pipeline sifatiga bogʻliq boʻladi.

