

Computer Vision bo'yicha 1–5-darslar boyicha summary

Umumiy katta rasm

Computer Vision bo'yicha 1-darsdan 5-darsgacha bo'lgan mavzular bitta to'liq yo'lni hosil qiladi. Bu yo'l rasm va videoni kompyuterga tushuntirishdan boshlanadi, keyin data tayyorlash, model tuzilishini tushunish, modelni o'qitish va oxirida modelni real hayotda ishlatish bosqichigacha olib boradi.

Umumiy yo'l quyidagicha:

Computer Vision nima?

↓

Image Classification nima?

↓

Data Preparation

↓

Model Architecture

↓

Training & Optimization

↓

Deployment & Inference

↓

Monitoring va real product

Bu yo'l Computer Vision projectini 0 dan boshlab product holatiga olib chiqish uchun kerak bo'lgan asosiy bilimlarni beradi. Birinchi darslarda nazariy tushunchalar o'rganiladi, keyingi darslarda esa projectni amaliy shaklda qanday qurish kerakligi tushuntiriladi.

Computer Vision — kompyuterga rasm va videolarni ko‘rish, tushunish, tahlil qilish va ulardan ma’no chiqarishni o‘rgatadigan sun’iy intellekt yo‘nalishi. Computer Vision qisqacha CV deb yoziladi. “Computer” — kompyuter, “Vision” — ko‘rish degani. O‘zbekchada “kompyuter ko‘rishi” deb tushuniladi.

Inson rasmni ko‘rganda darhol “bu mushuk”, “bu mashina”, “bu odam”, “bu matn” deb tushunadi. Kompyuter esa rasmni inson kabi tayyor ma’no bilan ko‘rmaydi. Kompyuter uchun rasm avval pixel qiymatlaridan iborat sonli ma’lumot hisoblanadi.

Pixel — rasmning eng kichik nuqtasi. Rangli rasm odatda RGB formatda bo‘ladi. RGB — Red, Green, Blue so‘zlarining qisqartmasi. Red — qizil, Green — yashil, Blue — ko‘k. Shu uch kanal birlashib rasm ranglarini hosil qiladi.

Shu sababli Computer Visionning asosiy maqsadi kompyuterga pixel qiymatlaridan ma’no chiqarishni o‘rgatish hisoblanadi.

1-dars: Computer Visionga kirish

Computer Vision nima?

Computer Vision sun’iy intellektning rasm va video bilan ishlaydigan yo‘nalishi hisoblanadi. Bu yo‘nalishda model rasm yoki videoni ko‘radi, ichidagi obyektlarni, shakllarni, ranglarni, harakatlarni yoki matnlarni tahlil qiladi va ma’lum natija chiqaradi.

Oddiy misollar:

rasmda mushuk bormi?

rasmda it bormi?

rasmda nechta odam bor?

mashinani qayerda ko‘rish mumkin?

rasmdagi matn nima?

videoda qanday harakat bo‘lyapti?

Computer Vision faqat rasmni ko‘rsatish emas, balki rasm ichidagi ma’noni topish bilan bog‘liq.

Misol sifatida mushuk va it rasmi olinadi. Inson ularni oson ajratadi.

Kompyuter esa avval rasmni raqamlar ko‘rinishida qabul qiladi.

Keyin model shu raqamlar ichidan featurelarni topadi. Feature — muhim belgi yoki xususiyat. Masalan, mushuk uchun quloq shakli, ko‘z, mo‘ylov, yuz tuzilishi feature bo‘lishi mumkin. It uchun tumshuq, quloq, tana shakli, yuz tuzilishi feature bo‘lishi mumkin.

Inson ko‘rishi va kompyuter ko‘rishi farqi

Inson ko‘radi, tushunadi va qaror qiladi. Kompyuter esa rasmni pixel qiymatlari sifatida oladi, model orqali tahlil qiladi va prediction chiqaradi.

Insondagi jarayon:

Ko‘z → Miya → Qaror

Computer Vision modelida:

Image → Model → Prediction

Image — rasm.

Model — ma’lumotdan pattern o‘rganadigan tizim.

Prediction — modelning taxmini yoki javobi.

Pattern — takrorlanadigan belgi, qonuniyat yoki ko‘rinish.

Inson miyasi tajriba asosida obyektlarni taniydi. Model ham training orqali ko‘p rasm ko‘rib, obyektlarni ajratishni o‘rganadi.

AI, ML, DL va CV o‘rtasidagi bog‘lanish

Computer Visionni yaxshi tushunish uchun AI, ML, DL va CV tushunchalarini ajratib olish kerak.

AI — Artificial Intelligence, ya’ni sun’iy intellekt. Bu kompyuterga inson kabi fikrlash, qaror qilish yoki vazifa bajarishni o‘rgatadigan katta yo‘nalish.

ML — Machine Learning, ya’ni mashinali o‘rganish. Bu AI ichidagi yo‘nalish bo‘lib, model data orqali o‘rganadi. Model qoida qo‘lda yozilmasdan, data asosida pattern topadi.

DL — Deep Learning, ya’ni chuqur o‘rganish. Bu ML ichidagi yo‘nalish bo‘lib, neural networklardan foydalanadi. Neural network — neyron tarmoq, ma’lumotdan murakkab patternlarni o‘rganadigan model.

CV — Computer Vision, ya’ni kompyuter ko‘rishi. Bu AI ichidagi rasm va video bilan ishlaydigan yo‘nalish. Amaliyotda CV ko‘pincha Deep Learning modellaridan foydalanadi.

Bog‘lanish:

AI → ML → DL → CV

Yoki ma’nosi:

Sun’iy intellekt

↓

Data orqali o‘rganish

↓

Neyron tarmoqlar orqali chuqur o'rganish

↓

Rasm va videoni tushunish

Nima uchun Computer Vision o'rganiladi?

Computer Vision bugungi kunda juda ko'p sohalarda ishlatiladi. Rasm, video, kamera, telefon, tibbiy tasvir, xavfsizlik kamerasi, avtomobil kamerasi, social media va e-commerce tizimlarida CV juda muhim.

Computer Vision o'rganish sabablari:

rasm va video data juda ko'p
social media va kamera tizimlari keng tarqalgan
AI multimodal yo'nalishga ketmoqda
GPU va hardware rivojlanmoqda
real productlarda CVga talab katta

Multimodal — bir nechta turdagi ma'lumot bilan ishlash. Masalan, matn + rasm + audio + video.

Hardware — qurilma imkoniyati. Masalan, GPU, kamera, edge device.

GPU — Graphics Processing Unit, grafik protsessor. Deep Learning training va inference jarayonlarini tezlashtirish uchun ishlatiladi.

Computer Vision ishlatiladigan sohalar:

autonomous driving
AI surveillance
medical AI

edge devices
social media
OCR systems
manufacturing quality control
agriculture
e-commerce

Autonomous driving — o‘zini o‘zi boshqaradigan avtomobil.

AI surveillance — sun’iy intellekt asosidagi kuzatuv tizimi.

Medical AI — tibbiy sun’iy intellekt.

Edge device — kichik qurilma, masalan telefon, kamera, Raspberry Pi yoki Jetson.

Computer Visionning asosiy bo‘limlari

Computer Vision ichida bir nechta muhim task bor. Task — vazifa.

Asosiy tasklar:

Image Classification

Object Detection

Segmentation

OCR

Pose Estimation

Video Classification

Image Classification

Image Classification — rasmni classga ajratish. Class — kategoriya yoki tur.

Masalan:

rasm → cat

rasm → dog

rasm → car

Model bitta rasimga qarab, rasm qaysi classga tegishli ekanini aytadi.

Object Detection

Object Detection — rasm ichidagi obyektlarni topish va ularning joylashgan o'rnini bounding box bilan ko'rsatish.

Bounding box — obyekt atrofidagi to'rtburchak ramka.

Masalan, rasmda odam, mashina va it bo'lsa, model har birini topadi va atrofini box bilan belgilaydi.

Segmentation

Segmentation — rasmni pixel darajasida ajratish. Ya'ni obyektning aniq chegarasi topiladi.

Mask — segmentation natijasida obyektни pixel bo'yicha ajratib ko'rsatadigan xarita.

Masalan, tibbiy rasmda o'pka, o'sma yoki kasallangan joy aniq ajratiladi.

OCR

OCR — Optical Character Recognition. O'zbekcha izohi: rasmdagi matnni o'qish texnologiyasi.

OCR ishlatiladigan joylar:

passport o'qish
ID karta o'qish
avtomobil raqamini o'qish
chekdagi matnni o'qish
kitob yoki hujjatni raqamlashtirish

Pose Estimation

Pose Estimation — inson tanasidagi nuqtalarni aniqlash. Masalan, bosh, yelka, tirsak, qo'l, tizza, oyoq joylashuvini topish.

Keypoints — tana nuqtalari.

Bu fitness app, sport tahlili, raqs harakati va xavfsizlik tizimlarida ishlatiladi.

Video Classification

Video Classification — video ichidagi harakat yoki holatni classga ajratish.

Masalan:

running
walking
fighting
falling
playing football
playing basketball
playing golf

Image Classification bitta rasm bilan ishlaydi. Video Classification esa ketma-ket frame bilan ishlaydi.

Frame — videodagi bitta rasm.

Computer Visiondagi qiyinchiliklar

CV projectlarda faqat model yozish yetarli emas. Real hayotda juda ko'p muammolar bo'ladi.

Asosiy qiyinchiliklar:

data yetishmasligi

labeling qimmat va sekin bo'lishi

GPU kerak bo'lishi

overfitting

lighting va noise muammolari

real world data farqi

Labeling — data'ga to'g'ri label berish jarayoni.

Overfitting — model training data'ni yodlab olib, yangi data'da yomon ishlashi.

Lighting — yorug'lik. Rasm turli yorug'likda bo'lsa, model qiynalishi mumkin.

Noise — shovqin. Rasm xira, donador yoki sifat past bo'lsa, model xato qilishi mumkin.

2-dars: Image Classification va Data Preparation

Image Classification nima?

Image Classification — Computer Visionning eng asosiy vazifalaridan biri. Bu vazifada model rasmni ko‘rib, uni ma’lum classga ajratadi.

Masalan:

mushuk rasmi → cat

it rasmi → dog

gul rasmi → flower

ovqat rasmi → food

yo‘l belgisi rasmi → traffic sign

Image Classification oddiy ko‘rinishi:

Input Image → Model → Class Prediction

Input Image — modelga kiradigan rasm.

Class Prediction — model tanlagan kategoriya.

Image Classification ko‘plab real projectlar uchun boshlang‘ich bosqich hisoblanadi. Chunki rasmni classga ajratishni tushunish orqali keyin object detection, segmentation va video classification kabi murakkab vazifalarni o‘rganish osonlashadi.

Image Classification turlari

Image Classification uchta asosiy turga bo‘linadi:

Binary Classification
Multi-Class Classification
Multi-Label Classification

Binary Classification

Binary Classification — faqat 2 ta classdan bittasini tanlash.

Binary — ikki turli degani.

Misollar:

cat yoki dog
disease yoki no disease
mask yoki no mask
defective yoki good
fraud yoki not fraud

Bu turda model bitta rasm uchun ikki variantdan bittasini tanlaydi.

Tibbiyotda:

kasallik bor
kasallik yo‘q

Ishlab chiqarishda:

mahsulot yaxshi
mahsulot nuqsonli

Security tizimida:

mask bor
mask yo‘q

Multi-Class Classification

Multi-Class Classification — ko‘p class ichidan faqat bittasini tanlash.

Misol:

cat
dog
horse
deer
bird
car
ship
truck

Rasm bitta classga tegishli bo‘ladi. Model ko‘p class ichidan eng mosini tanlaydi.

Masalan, traffic sign recognition vazifasida model yo‘l belgisini bir nechta class ichidan tanlaydi:

stop sign
speed limit
turn left
turn right
no entry

Multi-Label Classification

Multi-Label Classification — bitta rasmga bir nechta label berish.

Multi-label vazifada bitta rasmda bir nechta obyekt yoki xususiyat bo‘lishi mumkin.

Masalan:

person + car + tree
cat + dog
red + shirt + long sleeve

Social media image taggingda model rasmga bir nechta tag beradi.
Tag — rasm mazmunini bildiruvchi kalit so‘z.

Healthcare misolida bitta X-ray rasmda bir nechta kasallik belgisi bo‘lishi mumkin.

E-commerce misolida bitta mahsulot rasmi bir nechta label olishi mumkin:

red
dress
summer style
long sleeve

Binary, Multi-Class va Multi-Label farqi

Qisqa taqqoslash:

Binary → 2 classdan 1 tasi

Multi-Class → ko‘p classdan 1 tasi

Multi-Label → bir rasmga bir nechta label

Misol:

Binary:

cat yoki dog

Multi-Class:

cat, dog, horse, deer ichidan bittasi

Multi-Label:

person + car + tree

Binary va Multi-Classda odatda rasm uchun bitta yakuniy class bo'ladi. Multi-Labelda esa bir nechta class bir vaqtda to'g'ri bo'lishi mumkin.

Data Preparation nima?

Data Preparation — modelga beriladigan ma'lumotni tayyorlash jarayoni. Bu bosqich model natijasiga juda katta ta'sir qiladi. Data yomon bo'lsa, model architecture kuchli bo'lsa ham natija yomon bo'lishi mumkin.

Data Preparation quyidagi qismlardan iborat:

Data Acquisition

Preprocessing

Augmentation

Train / Validation / Test Split

Dataset Structure

Data Acquisition

Data Acquisition — rasm yig'ish va label berish.

Masalan, cat vs dog project uchun:

cat rasmlari yig'iladi

dog rasmlari yig'iladi

har rasmga to'g'ri label beriladi

Preprocessing

Preprocessing — rasmni modelga mos holatga keltirish.

Preprocessing ishlari:

resize

crop

normalize

tensor formatga o'tkazish

Resize — rasm o'lchamini o'zgartirish.

Normalize — pixel qiymatlarini model uchun qulay scale'ga keltirish.

Tensor — ko'p o'lchamli raqamlar massivi. Deep Learning modeli rasmni tensor sifatida qabul qiladi.

Augmentation

Augmentation — mavjud rasmlardan yangi ko'rinishlar yaratish.

Misollar:

rasmni aylantirish

rasmni chap-o'ngga ag'darish

yorug'likni o'zgartirish
contrastni o'zgartirish
random crop qilish

Augmentation modelni real hayotdagi turli holatlarga tayyorlaydi.

Dataset Structure

Image Classificationda dataset ko'pincha papka asosida tuziladi:

```
data/  
├── train/  
│   ├── cat/  
│   └── dog/  
├── val/  
│   ├── cat/  
│   └── dog/  
└── test/  
    ├── cat/  
    └── dog/
```

Bu folder-based labeling deyiladi. Folder-based labeling — papka nomiga qarab label berish usuli.

cat papkasidagi rasmlar cat labelini oladi. dog papkasidagi rasmlar dog labelini oladi.

Image Classification model yasash uchun kerakli fazalar

2-darsda model yasash uchun katta bosqichlar ko'riladi:

Phase 1: Data Preparation

Phase 2: Model Architecture

Phase 3: Training

Phase 4: Deployment

Bu keyingi darslarda alohida batafsil ochiladi.

3-dars: Data Preparation Review va Model Architecture

Data Preparation Review

3-darsda Data Preparation qayta ko‘rib chiqiladi va datasetlar bilan ishlash tushuntiriladi.

Data Preparationda muhim tushunchalar:

Data → Folder

Custom image workflow

Local folder path

Dataset size

File names

Download images

Workflow

Local folder path — dataset kompyuter ichida joylashgan papka yo‘li.

Dataset size — dataset hajmi. Har bir classda nechta rasm borligi ham muhim.

File names — fayl nomlari. Tartibli fayl nomlari datasetni boshqarishni osonlashtiradi.

Workflow — takrorlanadigan ishlar ketma-ketligi.

Custom image workflow — o‘z datasetini yig‘ishdan modelga berishgacha bo‘lgan maxsus jarayon.

Dataset manbalari

Computer Visionni o‘rganishda tayyor datasetlar muhim.

O‘tilgan datasetlar:

CIFAR10

CIFAR100

MNIST

FashionMNIST

SVHN

STL10

Flowers102

Food101

OxfordIIITPet

Caltech101

Torchvision Datasets

TensorFlow Datasets

Hugging Face Datasets

Kaggle Datasets

CIFAR10

CIFAR10 — 10 classli kichik rangli rasm dataset. Rasmlar 32×32 o‘lchamda bo‘ladi. Beginner uchun qulay.

CIFAR100

CIFAR100 — CIFAR10ga o‘xshash, lekin 100 classli. Qiyinroq classification vazifalari uchun ishlatiladi.

MNIST

MNIST — qoʻlda yozilgan raqamlar dataset. 0 dan 9 gacha boʻlgan raqamlar bor. Beginner uchun juda sodda.

FashionMNIST

FashionMNIST — kiyim-kechak rasmlaridan iborat dataset. MNISTga qaraganda realroq classification vazifasi.

SVHN

SVHN — Street View House Numbers. Real koʻcha rasmlaridagi raqamlar dataset. MNISTdan qiyinroq.

Flowers102

Flowers102 — 102 ta gul classidan iborat dataset. Fine-grained classification uchun foydali.

Fine-grained classification — bir-biriga juda oʻxshash classlarni ajratish.

Food101

Food101 — 101 ta ovqat kategoriyasidan iborat dataset. Real-world classification uchun yaxshi.

OxfordIIITPet

OxfordIIITPet — mushuk va it zotlari rasmlaridan iborat dataset. Breed classification va segmentation uchun ishlatilishi mumkin.

Breed — zot.

Kaggle, Hugging Face, TensorFlow Datasets

Bu platformalar turli dataset topish va yuklash uchun ishlatiladi.

Kaggle — dataset va competition platformasi.

Hugging Face Datasets — community datasetlar va ML datasetlar platformasi.

TensorFlow Datasets — tayyor ML datasetlar katalogi.

Model Architecture nima?

Model Architecture — modelning ichki tuzilishi. Architecture model qanday qatlamlardan iborat bo'lishini, input qanday qayta ishlanishini va output qanday chiqishini bildiradi.

Model Architecture oddiy ko'rinishi:

Input → Processing → Output

Computer Visionda:

Image → Layers → Prediction

Inson analogiyasi:

Ko'z → Miya → Qaror

CNN analogiyasi:

Image → CNN Layers → Prediction

CNN — Convolutional Neural Network. O'zbekchada konvolyutsion neyron tarmoq. Rasm bilan ishlashda eng asosiy model turlaridan biri.

Neural Network asosiy tushunchalari

Neural Network — qatlamlardan iborat model. U data'dan pattern o'rganadi.

Asosiy tushunchalar:

Layer

Weights

Bias

Forward Pass

Loss Function

Gradient Descent

Backpropagation

Optimizer

Learning Rate

Epoch

Batch

Overfitting

Regularization

Evaluation Metrics

Layer — qatlam.

Weights — model o'rganadigan vazn qiymatlari.

Bias — hisoblashga qo'shimcha moslashuv beradigan qiymat.

Forward Pass — inputdan outputgacha oldinga o'tish.

Loss Function — xatoni hisoblaydigan funksiya.

Gradient Descent — lossni kamaytirish uchun weightlarni yangilash usuli.

Backpropagation — xatoni orqaga tarqatish.

Optimizer — weightlarni yangilaydigan algoritm.

Learning Rate — yangilash qadamining kattaligi.

Epoch — butun datasetdan bir marta o'tish.

Batch — datasetning kichik qismi.

Overfitting — model training data'ni yodlab olib, yangi data'da yomon ishlashi.

Regularization — overfittingni kamaytirish usullari.

Backbone, Neck, Head

Computer Vision modellari ko'pincha 3 qism bilan tushuntiriladi:

Backbone

Neck

Head

Backbone

Backbone — feature extraction qiladigan asosiy qism. Backbone rasm ichidan muhim featurelarni ajratadi.

Masalan:

qirra

chiziq

ko'z

quloq

g'ildirak

barg

hayvon yuzi

Neck

Neck — backbone va head orasidagi bog‘lovchi qism. Featurelarni tartiblaydi, ixchamlaydi yoki headga mos formatga keltiradi.

Global Average Pooling neck vazifasini bajarishi mumkin.

Global Average Pooling — feature mapni vector ko‘rinishiga keltirish.

Head

Head — yakuniy qaror chiqaradigan qism. Image Classificationda class probability chiqaradi.

Masalan:

Cat: 85%

Dog: 15%

CNN qatlamlari

CNN modelida asosiy qatlamlar:

Input Layer

Convolutional Layers

Pooling Layers

Global Average Pooling

Fully Connected Layer

Softmax

Input Layer

Input Layer — rasm modelga kiradigan qatlam.

Masalan:

$$224 \times 224 \times 3$$

Bu 224 balandlik, 224 kenglik va 3 RGB kanal degani.

Convolutional Layers

Convolutional Layers — filterlar orqali rasm ichidan featurelarni ajratadigan qatlamlar.

Filter — rasm ustida harakat qilib feature topadigan kichik matematik oynacha.

Pooling Layers

Pooling Layers — feature map hajmini kamaytiradi.

Turlari:

Max Pooling

Average Pooling

Max Pooling — eng katta qiymatni oladi.

Average Pooling — oʻrtacha qiymatni oladi.

Fully Connected Layer

Fully Connected Layer — yakuniy qaror chiqarishga yordam beradigan zich bogʻlangan qatlam.

Softmax

Softmax — class scorelarni probabilityga aylantiradi.

4-dars: Training & Optimization

Training & Optimization nima?

4-darsda model architecture qanday oʻrganishi tushuntiriladi. Model architecture borligi model oʻrgandi degani emas. Model training orqali oʻrganadi.

Training — modelni data orqali oʻqitish.

Optimization — model xatosini kamaytirish uchun weightlarni yangilash.

Trainingning umumiy flowi:

Input → Model → Prediction → Loss → Backpropagation
→ Optimizer Step → Better Model

Forward Pass

Forward Pass — input modeldan oldinga qarab oʻtib prediction hosil qiladigan jarayon.

Input → Model → Output

Image Classificationda:

Image → CNN → Prediction

Forward passda weightlar yangilanmaydi. Model faqat hozirgi weightlar asosida javob beradi.

Loss

Loss — model predictioni haqiqiy javobdan qanchalik uzoq ekanini o'lchaydi.

Misol:

True label: Dog

Model prediction:

Dog: 0.30

Cat: 0.65

Bird: 0.05

Bu yerda model xato qilgan, chunki haqiqiy class Dog bo'lsa ham, Catga ko'proq probability bergan.

Lossni tushunish usullari:

Wrong-class confidence

Simple true-label error

Cross-Entropy Loss

Cross-Entropy Loss

Formula:

$$\text{Loss} = -\log(P(\text{true class}))$$

Agar $P(\text{true class}) = 0.30$ bo'lsa:

Loss ≈ 1.20

Haqiqiy class probabilitysi yuqori bo'lsa, loss kichik bo'ladi. Haqiqiy class probabilitysi past bo'lsa, loss katta bo'ladi.

Backpropagation

Backpropagation — xatoni orqaga tarqatish jarayoni.

Forward pass prediction chiqaradi. Loss xatoni o'lchaydi.

Backpropagation shu xatoni model ichidagi qatlamlarga orqaga qaytarib, gradientlarni hisoblaydi.

Gradient — weight qaysi yo'nalishda o'zgarishi kerakligini ko'rsatadigan qiymat.

Backpropagation modelga “qayerni va qanday tuzatish kerak” degan signal beradi.

Optimizer

Optimizer — gradientlardan foydalanib weightlarni yangilaydigan algoritm.

Mashhur optimizerlar:

SGD

Adam

RMSprop

AdamW

Optimizer formulasi sodda ko'rinishda:

$$\text{New weight} = \text{Old weight} - \text{Learning Rate} \times \text{Gradient}$$

Learning Rate

Learning Rate — weight update qadamining kattaligi.

Agar learning rate juda kichik bo'lsa:

training juda sekin bo'ladi
loss juda sekin kamayadi

Agar learning rate juda katta bo'lsa:

model tebranadi
loss oshib ketishi mumkin
training diverge bo'ladi

Diverge — trainingning beqaror bo'lib ketishi.

Mos learning rate lossni barqaror kamaytiradi.

Epoch va Batch

Batch — datasetning kichik qismi.

Epoch — model butun training datasetni bir marta to'liq ko'rib chiqishi.

Misol:

Dataset = 1000 rasm

Batch size = 100

1 epoch = 10 batch

Agar 5 epoch train qilinsa:

10 batch × 5 epoch = 50 training step

Training step — bitta batch bo'yicha forward pass, loss, backward pass va optimizer step bajarilishi.

PyTorch training loop

Training loop quyidagicha:

```
for images, labels in train_loader:
    optimizer.zero_grad()
    outputs = model(images)
    loss = criterion(outputs, labels)
    loss.backward()
    optimizer.step()
```

`optimizer.zero_grad()` — eski gradientlarni tozalaydi.

`outputs = model(images)` — forward pass.

`loss = criterion(outputs, labels)` — loss hisoblash.

`loss.backward()` — backpropagation.

`optimizer.step()` — weightlarni yangilash.

Training loop qisqa formula:

Forward → Loss → Backward → Step → Repeat

Trainingdagi muhim muammolar

Trainingda kuzatiladigan muammolar:

learning rate kichik
learning rate katta
loss pasaymasligi
overfitting
batch size noto'g'ri tanlanishi
monitoring qilinmasligi

Overfitting belgisi:

train accuracy yuqori
validation accuracy past

Yechimlar:

augmentation
dropout
regularization
early stopping
ko'proq data
modelni kichraytirish

5-dars: Deployment & Inference

Trainingdan keyingi bosqich

Model train qilindi, lekin hali real product emas. Model foydalanuvchi ishlata oladigan tizimga chiqarilsa, deployment bosqichi boshlanadi.

5-darsning asosiy g'oyasi:

Training = model o'rganadi

Inference = model javob beradi

Deployment = modelni foydalanuvchi ishlata oladigan ko'rinishga olib chiqish

Phase 4: Deployment & Inference

Phase 4 quyidagilardan iborat:

Deployment Optimization

Inference

Monitoring

Final Output

Deployment Optimization

Deployment Optimization — modelni tezroq, yengilroq va production-friendly qilish.

Production-friendly — real tizimda ishlatishga qulay.

Usullar:

Quantization

ONNX export

TensorRT

faster runtime

Quantization — modeldagi float32 sonlarni int8 kabi kichik formatga o'tkazish. Bu model hajmini kamaytiradi va inference tezligini oshiradi.

ONNX — Open Neural Network Exchange. Turli framework va runtime orasida modelni ko‘chirish uchun universal format.

TensorRT — NVIDIA GPU uchun optimallashtirilgan inference engine.

Runtime — model ishga tushadigan muhit.

Optimization quyidagilarni yaxshilaydi:

Model Size

Inference Speed

Latency

Portability

Model Size — model hajmi.

Inference Speed — modelning javob berish tezligi.

Latency — requestdan responsegacha ketgan vaqt.

Portability — modelni turli muhitlarda ishlatish qulayligi.

Deployment nima?

Deployment — train qilingan modelni real foydalanuvchi ishlata oladigan tizimga joylash va ishga tushirish.

Deployment flow:

Trained Model

↓

Optimize

↓

Wrap in API/App

↓

Deploy to Server/Device

↓

User Uses It

Trained Model — o‘qitilgan model.

Optimize — modelni yengillashtirish va tezlashtirish.

Wrap in API/App — modelni API yoki app ichiga o‘rash.

API — Application Programming Interface. Boshqa dasturlar modelga request yuborib, response olishi uchun interfeys.

Server — foydalanuvchi requestlarini qabul qilib javob qaytaradigan kompyuter yoki cloud muhit.

Device — qurilma, masalan telefon, Raspberry Pi, Jetson yoki laptop.

Deployment natijasida foydalanuvchi rasm yuklaydi va prediction oladi.

Inference nima?

Inference — training tugagandan keyin modelning yangi data ustida prediction berishi.

Inference flow:

Input Image

↓

Preprocess

↓

Model Runs

↓

Probabilities

↓

Predicted Class

Preprocess — rasmni modelga mos holatga keltirish.

Inference paytida:

weightlar o'zgarmaydi
backpropagation bo'lmaydi
faqat forward pass ishlaydi

PyTorch inference uchun:

```
model.eval()
```

```
with torch.no_grad():  
    image = preprocess(img).unsqueeze(0)  
    outputs = model(image)  
    probs = torch.softmax(outputs, dim=1)  
    pred = probs.argmax(dim=1).item()
```

`model.eval()` — modelni inference modega o'tkazadi.

`torch.no_grad()` — gradient hisoblashni o'chiradi.

`softmax` — scorelarni probabilityga aylantiradi.

`argmax` — eng katta probabilityga ega classni tanlaydi.

Deployment vs Inference

Deployment va Inference farqi:

Deployment = modelni real tizimga joylashtirish
Inference = modeldan yangi data uchun prediction olish

Deployment system-level task hisoblanadi. Ya'ni server, API, app, security, scalability, optimization bilan bog'liq.

Inference prediction-level task hisoblanadi. Ya'ni bitta user requestga model javob beradi.

Monitoring

Monitoring — deploy qilingan modelning vaqt o'tishi bilan ishlashini kuzatish.

Monitoringda kuzatiladiganlar:

Accuracy

Latency

Drift

Failures

Prediction distribution

Accuracy — predictionlar to'g'riligi.

Latency — bitta requestga javob vaqti.

Drift — real data training data'dan farq qilib ketishi.

Failures — crash, timeout, xatolar.

Prediction distribution — model qaysi classlarni qanchalik ko'p prediction qilayotganini ko'rsatadi.

Monitoring kerak, chunki model productga chiqqandan keyin real data o'zgarishi mumkin. Model vaqt o'tishi bilan yomonlashishi mumkin. Bunday holatda retraining kerak bo'ladi.

Retraining — modelni yangi data bilan qayta train qilish.

Cat vs Dog real use example

Cat vs Dog model web appga deploy qilinsa, oqim quyidagicha bo'ladi:

1. User uploads image
2. App preprocesses image
3. Model inference
4. Output: Dog 0.98
5. Log & monitor

Frontend — foydalanuvchi rasm yuklaydigan interfeys.

Backend — requestni qabul qilib modelga yuboradigan server qismi.

Model Runtime — model ishlaydigan muhit. PyTorch, ONNX Runtime yoki TensorRT bo'lishi mumkin.

Monitoring — logs, response time va prediction distributionni kuzatadi.

Qayerga deploy qilish mumkin?

Deployment joylari:

Local / Edge Deployment

Cloud / Server Deployment

Local / Edge Deployment

Misollar:

Laptop

Local server

Raspberry Pi

Jetson

Offline app

Afzalliklari:

tez prototyping

privacy yaxshi

internet shart emas

Kamchiliklari:

scale cheklangan

qurilma kuchi muhim

Cloud / Server Deployment

Misollar:

VPS

AWS

GCP

Azure

Render

Railway

On-prem server

Afzalliklari:

ko'p foydalanuvchi uchun mos
API qilish oson
monitoring va scaling qulay

Kamchiliklari:

xarajat bor
internetga bog'liq

Deploymentdagi muammolar

Muammolar va yechimlar:

Model sekin ishlayapti → Quantization, ONNX,
smaller model

Memory yetmayapti → image size kichraytirish,
lighter backbone

Prediction sifati pasaydi → monitoring, retraining,
drift analysis

Different environment error → requirements.txt,
Docker

API timeout → async queue, caching, stronger server

User experience yomon → simple UI, progress
indicator, clear output

Docker — projectni bir xil environmentda ishga tushirish uchun
container texnologiyasi.

Environment — dastur ishlaydigan muhit.

Caching — oldingi natijani saqlab qayta ishlatish.

Async queue — requestlarni navbatga qo'yib fon rejimida qayta ishlash.

1–5-darslar bo'yicha umumiy roadmap

Barcha 5 dars birga quyidagi project roadmapni hosil qiladi:

1. Computer Visionni tushunish
2. Image Classification vazifasini tushunish
3. Dataset topish va tayyorlash
4. Preprocessing va Augmentation qilish
5. Model Architecture qurish
6. Backbone, Neck, Head tushunish
7. Forward Pass orqali prediction olish
8. Loss orqali xatoni o'lchash
9. Backpropagation orqali gradient hisoblash
10. Optimizer orqali weight yangilash
11. Epoch va Batch orqali trainingni tashkil qilish
12. Modelni baholash
13. Best modelni saqlash
14. Inference pipeline tayyorlash
15. Deployment optimization qilish
16. API yoki app orqali deploy qilish
17. Monitoring qilish
18. Xato bo'lsa retraining qilish

Bu yo'l 0 dan productgacha bo'lgan Computer Vision projectni tushuntiradi.

Bitta Image Classification project to'liq oqimi

Misol sifatida Cat vs Dog project olinadi.

Dataset yig'iladi

↓

cat va dog papkalari tuziladi

↓

train / val / test split qilinadi

↓

rasmlar resize va normalize qilinadi

↓

augmentation qo'shiladi

↓

CNN yoki pretrained model tanlanadi

↓

model forward pass qiladi

↓

loss hisoblanadi

↓

backpropagation gradientlarni hisoblaydi

↓

optimizer weightlarni yangilaydi

↓

model bir necha epoch train qilinadi

↓

validation natija kuzatiladi

↓

best_model.pth saqlanadi

↓

inference script yoziladi

↓

model.eval() va torch.no_grad() ishlatiladi
↓
Softmax probability beradi
↓
Gradio yoki FastAPI orqali app qilinadi
↓
model local yoki serverga deploy qilinadi
↓
foydalanuvchi rasm yuklaydi
↓
model Dog 0.98 kabi natija qaytaradi
↓
logs va monitoring orqali ishlash kuzatiladi

Eng muhim tushunchalar lugʻati

Computer Vision — kompyuterga rasm va videoni tushunishni oʻrgatadigan AI yoʻnalishi.

Image Classification — rasmni classga ajratish.

Class — kategoriya yoki tur.

Label — toʻgʻri javob.

Dataset — maʼlumotlar toʻplami.

Pixel — rasmning eng kichik nuqtasi.

RGB — Red, Green, Blue rang kanallari.

Preprocessing — rasmni modelga mos tayyorlash.

Augmentation — rasmlarni turli koʻrinishga keltirib datasetni boyitish.

Model Architecture — modelning ichki tuzilishi.

CNN — rasm bilan ishlash uchun ishlatiladigan konvolyutsion neyron tarmoq.

Backbone — feature extraction qiladigan asosiy qism.

Neck — featurelarni tartiblaydigan oraliq qism.

Head — yakuniy prediction chiqaradigan qism.

Feature — rasm ichidagi foydali belgi.

Forward Pass — inputdan outputgacha oldinga hisoblash.

Loss — model xatosini oʻlchaydigan qiymat.

Backpropagation — xatoni orqaga tarqatish.

Gradient — lossni kamaytirish yoʻnalishi.

Optimizer — weightlarni yangilaydigan algoritm.

Learning Rate — yangilash qadamining kattaligi.

Batch — datasetning kichik qismi.

Epoch — butun datasetdan bir marta oʻtish.

Overfitting — model training data'ni yodlab olib, yangi data'da yomon ishlashi.

Deployment — modelni real tizimga joylash.

Inference — yangi data ustida prediction olish.

Monitoring — deploy qilingan model ishlashini kuzatish.

Latency — requestga javob qaytish vaqti.

Drift — real data training data'dan farq qilib ketishi.

Quantization — model son formatlarini kichraytirib, modelni yengillashtirish.

ONNX — modelni turli muhitlarda ishlatish uchun universal format.

TensorRT — NVIDIA GPUda inference'ni tezlashtiradigan engine.

Yakuniy katta xulosa

1–5-darslar Computer Vision projectining to'liq asosini beradi. Birinchi darsda Computer Vision nima ekani, kompyuter rasmni qanday tushunishi, AI/ML/DL/CV bog'lanishi va CV tasklari o'rganiladi. Ikkinchi darsda Image Classification chuqurroq tushuntiriladi, binary, multi-class va multi-label classification farqlari ko'riladi, data preparationning ahamiyati o'rganiladi. Uchinchi darsda datasetlar, custom workflow va model architecture tushuntiriladi; backbone, neck, head, convolutional layer, pooling, fully connected layer va softmax kabi qismlar tartibga solinadi. To'rtinchi darsda architecture qanday o'rganishi ko'rsatiladi: forward pass, loss, backpropagation, optimizer, learning rate, epoch va batch orqali model training qilinadi. Beshinchi darsda train qilingan modelni real hayotda ishlatish, deployment, inference, monitoring, optimization va final prediction jarayoni tushuntiriladi.

Barcha darslar birgalikda shuni ko'rsatadi: Computer Vision project faqat model train qilishdan iborat emas. Avval muammo tushuniladi, data tayyorlanadi, model architecture tanlanadi, model training orqali o'rganadi, evaluation qilinadi, best model saqlanadi, inference pipeline yoziladi, model app yoki API orqali deploy qilinadi va productda monitoring qilinadi. Shu bosqichlar to'liq bajarilganda Computer Vision modeli real foydalanuvchiga foyda bera oladigan productga aylanadi.