

Lesson 7 — Object Detection Introduction

CV uchburchagi: Computer Visiondagi 3 asosiy vazifa

Computer Vision ichida uchta katta asosiy vazifa bor: Image Classification, Object Detection va Segmentation. Bu uchulasi bir-biriga bog‘liq, lekin ular rasmni turlicha darajada tushunadi.

Computer Vision — kompyuterga rasm va videolarni ko‘rish, tushunish va ulardan ma’no chiqarishni o‘rgatadigan yo‘nalish. CV qisqartmasi “Computer Vision” degani.

CV uchburchagi misol sifatida olinsa, uchta asosiy yo‘nalish alohida-alohida ko‘rsatiladi:

Image Classification

Object Detection

Segmentation

Bu uchalasini farqlash juda muhim, chunki modelning outputi, ishlatiladigan dataset, label formati, metricalari va model architecture’si vazifa turiga qarab o‘zgaradi.

Image Classification

Image Classification — rasm ichida nima borligini aniqlash vazifasi. Bu vazifada model rasmga qarab bitta yoki bir nechta label chiqaradi, lekin obyekt joylashuvini ko‘rsatmaydi.

Image Classification savoli:

NIMA bor?

Javob:

Bu it

Bu yerda model faqat rasmda it borligini aytadi. Lekin it rasmning qayerida turgani, necha pixel joy egallagani yoki uning atrofidagi chegarasi ko'rsatilmaydi.

Image Classification outputi odatda shunday bo'ladi:

dog

cat

car

horse

deer

Output — modeldan chiqqan natija.

Label — class nomi yoki to'g'ri javob. Masalan, dog, cat, car.

Class — kategoriya yoki tur.

Image Classification'da bounding box ishlatilmaydi. Bounding box — obyekt atrofini o'rab turuvchi to'rtburchak. Image Classification uchun bunday to'rtburchak kerak emas, chunki vazifa faqat "rasmda nima bor?" degan savolga javob berishdan iborat.

Misol:

Input image → Model → Dog

Bu model rasmni dog classiga ajratadi. Lekin dog qayerda joylashganini aytmaydi.

Object Detection

Object Detection — rasm ichida nima borligini va u qayerda joylashganini aniqlash vazifasi. Bu Image Classification'dan keyingi murakkabroq bosqich hisoblanadi.

Object Detection savoli:

NIMA + QAYERDA?

Javob:

It: [x, y, w, h]

Bu yerda model faqat it borligini emas, balki itning rasm ichidagi joylashuvini ham beradi.

[x, y, w, h] — bounding box formatlaridan biri. Bu yerda:

x → box boshlanish yoki markaz koordinatasi

y → box boshlanish yoki markaz koordinatasi

w → width, ya'ni kenglik

h → height, ya'ni balandlik

Width — kenglik.

Height — balandlik.

Coordinate — rasm ichidagi joylashuvni bildiruvchi son.

Object Detection outputi odatda quyidagilardan iborat bo‘ladi:

class label
bounding box
confidence score

Class label — obyekt turi. Masalan, person, car, dog.

Bounding box — obyektning o‘rab turuvchi to‘rtburchak.

Confidence score — modelning ishonch darajasi. Masalan, 0.97 model 97% ishonch bilan prediction qilganini bildiradi.

Object Detection modelining natijasi shunday bo‘lishi mumkin:

person 0.97 [x, y, w, h]
car 0.92 [x, y, w, h]
dog 0.85 [x, y, w, h]

Bu yerda model bir vaqtning o‘zida uchta obyektning topadi: person, car va dog. Har bir obyekt uchun alohida bounding box va confidence score bor.

Segmentation

Segmentation — rasm ichidagi obyektlarni pixel darajasida ajratish vazifasi. Bu vazifa Image Classification va Object Detection’dan ham aniqroq natija beradi.

Segmentation savoli:

QAYSI PIXEL?

Javob:

Piksel-piksel mask

Pixel — rasmning eng kichik nuqtasi.

Mask — obyekt qaysi pixellardan iborat ekanini ko'rsatadigan ajratish xaritasi.

Segmentation modelida obyekt atrofida oddiy to'rtburchak chizish bilan cheklanilmaydi. Har bir pixel qaysi obyektga tegishli ekanini ajratish kerak bo'ladi. Shu sababli segmentation eng aniq, lekin eng og'ir vazifalardan biri hisoblanadi.

Object Detection obyektни to'rtburchak bilan ko'rsatadi.

Segmentation esa obyektning real shakliga yaqin hududini ajratadi.

Misol:

Object Detection → it atrofida box

Segmentation → it tanasiga tegishli pixellar mask bo'lib ajratiladi

Segmentation tibbiyot, avtonom mashinalar, sun'iy yo'ldosh rasmlari va aniq obyekt ajratish kerak bo'lgan sohalarda juda muhim.

CV uchburchagi umumiy farqi

Uchta vazifa orasidagi farq quyidagicha tushuniladi:

Image Classification → faqat nima borligini aytadi

Object Detection → nima borligini va qayerda ekanini aytadi

Segmentation → qaysi pixel qaysi obyektga tegishli ekanini aytadi

Oddiy misol:

Classification:

Rasmda it bor

Object Detection:

It rasmning chap pastki qismida, box koordinatalari bilan

Segmentation:

It tanasiga tegishli barcha pixellar alohida mask sifatida ajratilgan

Shu sababli Object Detection Image Classification'dan ko'proq ma'lumot beradi, lekin Segmentation'dan yengilroq hisoblanadi.

Object Detection misollari

Ko'p odamli joyda obyektlarni aniqlash

Aeroport yoki kutish zalidagi odamlar misol sifatida olinsa, model bir nechta odamni alohida obyekt sifatida topadi. Har bir odam atrofida bounding box chiziladi va person labeli qo'yiladi. Ba'zi obyektlarda confidence score ham ko'rinadi. Masalan:

person 0.87

person 0.70

person 0.90

Bu qiymatlar modelning har bir odamni nechchi foiz ishonch bilan topganini bildiradi. person 0.90 degani model bu obyekt odam ekaniga 90% ishonadi.

Bu misolda bir nechta muhim narsa ko‘rinadi:

bitta rasm ichida bir nechta obyekt bor
har bir obyekt alohida box bilan belgilanadi
har bir obyekt uchun class label chiqadi
har bir obyekt uchun confidence score bo‘ladi

Shu yerda Image Classification yetarli bo‘lmaydi. Chunki Image Classification faqat “rasmda odam bor” deyishi mumkin. Object Detection esa “qaysi odam qayerda?” degan savolga ham javob beradi.

Masalan, kutish zalida uchta odam va bitta chamadon bo‘lsa, detection modeli har birini alohida topishi kerak:

person → chap tomonda
person → o‘rtada
person → o‘ng tomonda
suitcase → pastki markazda

Suitcase — chamadon.

Bu real hayotdagi security camera, airport monitoring, crowd analysis kabi vazifalarda kerak bo‘ladi.

Security camera — xavfsizlik kamerasi.

Crowd analysis — odamlar oqimini tahlil qilish.

Avtomobil va yo‘l sahnasida Object Detection

Avtomobil ichidan yo‘lga qaralgan holat misol sifatida olinsa, self-driving system uchun Object Detection juda muhim bo‘ladi. Self-driving — o‘zini o‘zi boshqaradigan avtomobil tizimi.

Yo‘l sahnasida model quyidagi obyektlarni topishi kerak:

car

person

traffic light

road sign

lane

motorcycle

truck

bus

Lane — yo‘l chizig‘i yoki yo‘l polosasi.

Traffic light — svetofor.

Road sign — yo‘l belgisi.

Self-driving tizimida model faqat obyekt borligini bilib qolmaydi, uning joylashuvini ham bilishi kerak. Chunki avtomobil qaror qabul qilishi uchun obyekt qayerda, qanchalik yaqin, qaysi tomonda ekanini bilish zarur.

Masalan:

person → oldinda

car → chap tomonda

traffic light → yuqorida
lane → yo‘l markazida

Bitta yo‘l sahnasida piyodalar, sumkalar, mashinalar va yo‘l chiziqlari alohida bounding box yoki boshqa visual belgilar bilan ko‘rsatiladi. Bu Object Detection’ning real-time ishlashi kerak bo‘lgan eng muhim sohalaridan biri.

Real-time — real vaqt rejimida ishlash. Ya’ni model juda tez javob berishi kerak.

Self-driving tizimida kechikish katta bo‘lsa, xavfsizlikka salbiy ta’sir qiladi. Shuning uchun YOLO kabi tez ishlaydigan One-Stage detectorlar real-time tizimlarda ko‘p ishlatiladi.

Tibbiy tasvirlarda Object Detection

Tibbiy tasvirlar misol sifatida olinsa, Object Detection rentgen, X-ray, dental scan va boshqa medical imaging ma’lumotlarida kasallik belgilarini topishga yordam beradi.

Medical imaging — tibbiy tasvirlar bilan ishlash.

X-ray — rentgen tasviri.

Dental X-ray — tish rentgen tasviri.

Tish rentgenida model tish qismlarini yoki dental implant joylarini aniqlashi mumkin. Har bir tish yoki tibbiy obyekt alohida box yoki label bilan belgilanadi. Bu stomatologiya diagnostikasida yordam beradi.

Ko‘krak qafasi X-ray tasvirida model turli anatomik qismlar, shikastlanish yoki kasallik belgilarini ajratishi mumkin. Masalan,

o'pka hududi, yurak sohasi, suyaklar yoki shubhali dog'lar ko'rsatiladi.

Cancer detection misolida cancer 0.74 kabi natija chiqadi. Bu model ko'rsatilgan hududni 74% ishonch bilan cancer, ya'ni saraton bilan bog'liq shubhali joy deb topganini bildiradi.

Bu yerda confidence score shifokor qarorini to'liq almashtirmaydi. U yordamchi signal sifatida ishlatiladi. Medical AI tizimlarida model natijasi radiolog yoki shifokor tekshiruvi bilan birga ko'rib chiqiladi.

Radiolog — rentgen va tibbiy tasvirlarni tahlil qiladigan shifokor.

Tibbiy Object Detection'da tezlikdan ko'ra aniqlik ko'proq muhim bo'ladi. Shu sababli Faster R-CNN yoki yuqori aniqlik beradigan Two-Stage detectorlar tibbiy vazifalarda foydali bo'ladi.

Classification, Localization, Detection va Segmentation farqi

Computer Vision vazifalari bir-biridan output darajasi bilan farq qiladi. Mushuk, it va boshqa obyektlar misol sifatida olinsa, har bir task turli savolga javob beradi.

Semantic Segmentation

Semantic Segmentation — har bir pixelni classga ajratish. Semantic — ma'no yoki class darajasidagi ajratish degani.

Semantic Segmentation natijasida rasm ichidagi hududlar class bo'yicha bo'yaladi:

grass

cat

tree
sky

Grass — o‘t.

Tree — daraxt.

Sky — osmon.

Semantic Segmentation obyekt instance’larini alohida ajratmaydi. Masalan, rasmda ikki it bo‘lsa, ikkalasi ham **dog** classiga tegishli pixel sifatida belgilanadi, lekin “birinchi it” va “ikkinchi it” deb alohida ajratilmaydi.

Instance — bir obyektning alohida nusxasi.

Classification + Localization

Classification + Localization — rasmda bitta asosiy obyekt bor deb olinadi va model shu obyektning classini hamda joylashuvini topadi.

Localization — obyektning qayerda ekanini aniqlash.

Misol:

class → cat

box → mushuk atrofida to‘rtburchak

Bu vazifada odatda bitta obyekt bor deb qaraladi. Model “bu cat” deb aytadi va cat qayerdaligini box bilan ko‘rsatadi.

Classification + Localization Image Classification’dan kuchliroq, lekin Object Detection’dan soddaroq. Chunki unda ko‘p obyektни alohida topish shart emas.

Object Detection

Object Detection ko‘p obyektli sahnalar uchun ishlatiladi. Rasm ichida bir nechta obyekt bo‘lsa, har biri alohida topiladi.

Misol:

dog

dog

cat

Har bir obyekt uchun alohida bounding box va class label chiqadi. Agar rasmda ikkita dog va bitta cat bo‘lsa, model uchta obyektни alohida ko‘rsatadi.

Bu yerda asosiy farq shuki, Object Detection multiple object, ya’ni ko‘p obyektни topadi.

Multiple object — bir nechta obyekt.

Instance Segmentation

Instance Segmentation — har bir obyekt instance’ini pixel darajasida ajratish. Bu Segmentation va Detection orasidagi yanada aniqroq vazifa hisoblanadi.

Agar rasmda ikkita dog va bitta cat bo‘lsa, Instance Segmentation ularning har birini alohida rang yoki mask bilan ajratadi:

dog 1

dog 2

cat 1

Bu Object Detection'dan aniqroq, chunki faqat box emas, obyektning real shakliga yaqin pixel mask ham chiqadi.

To'rt vazifa orasidagi tartib

Bu vazifalar murakkablik bo'yicha shunday ketadi:

Classification

↓

Classification + Localization

↓

Object Detection

↓

Instance Segmentation

Murakkablik oshgani sari model ko'proq ma'lumot beradi, lekin ko'proq data, ko'proq hisoblash quvvati va murakkab annotation talab qiladi.

Annotation — rasmga label, box yoki mask qo'yish jarayoni.

Asosiy tushunchalar — Key Terms

Object Detectionni tushunish uchun bir nechta asosiy terminlarni bilish kerak: Bounding Box, Class Label, Confidence Score, IoU, Anchor Box va NMS.

Bounding Box — BBox

Bounding Box yoki BBox — obyektни o'rab oladigan to'rtburchak. BBox obyektning rasm ichidagi joylashuvini ko'rsatadi.

BBox formatlari turlicha bo'lishi mumkin. Eng sodda ko'rinish:

(x, y, w, h)

Bu yerda:

x → boxning x koordinatasi

y → boxning y koordinatasi

w → box kengligi

h → box balandligi

Bounding box Object Detection uchun eng asosiy outputlardan biri. Model “nima bor?” degan savolga class label bilan javob beradi, “qayerda?” degan savolga bounding box bilan javob beradi.

Class Label

Class Label — obyekt turi. Masalan:

car

person

dog

cat

bicycle

traffic light

Class label model topgan obyekt qaysi kategoriya ekanini bildiradi.

Misol:

person 0.97

Bu yerda person class label, 0.97 confidence score bo‘ladi.

Confidence Score

Confidence Score — modelning predictionga ishonch darajasi. U odatda 0.0 dan 1.0 gacha bo'ladi.

0.0 → ishonch yo'q

1.0 → maksimal ishonch

0.9 → 90% ishonch

Confidence score model topgan obyektни ko'rsatish yoki tashlab ketish uchun ishlatiladi. Agar confidence juda past bo'lsa, model predictionni ko'pincha ko'rsatilmaydi.

Masalan:

dog 0.85

Bu model obyektни 85% ishonch bilan dog deb topganini bildiradi.

IoU — Intersection over Union

IoU — Intersection over Union. O'zbekcha izohi: kesishuv maydoni bilan birlashuv maydoni nisbati.

IoU predicted box va actual box qanchalik o'xshash ekanini o'lchaydi.

Predicted box — model bashorat qilgan box.

Actual box yoki ground truth box — haqiqiy box, ya'ni annotationdagi to'g'ri box.

IoU formulasi:

$\text{IoU} = \text{Kesishuv maydoni} / \text{Birlashuv maydoni}$

Agar predicted box va actual box aynan bir xil bo'lsa:

$\text{IoU} = 1.0$

Agar ular umuman ustma-ust tushmasa:

$\text{IoU} = 0.0$

IoU Object Detection metrichlarida juda muhim. Chunki model classni to'g'ri topishi bilan birga boxni ham to'g'ri joyga qo'yishi kerak.

Anchor Box

Anchor Box — oldindan belgilangan box o'lchamlari. Model anchor boxlar atrofida real bounding boxni bashorat qiladi.

Anchor — tayanch degani.

Anchor boxlar turli o'lcham va nisbatlarda bo'ladi. Masalan, uzun obyekt, keng obyekt yoki kichik obyekt uchun alohida anchorlar ishlatiladi.

Model anchor boxni boshlang'ich taxmin sifatida oladi va uni real obyektga moslab o'zgartiradi.

NMS — Non-Max Suppression

NMS — Non-Max Suppression. O'zbekcha izohi: bir obyekt uchun chiqqan ortiqcha boxlarni kamaytirish va faqat eng yaxshi boxni qoldirish.

Object Detection model ba'zan bitta obyekt uchun bir nechta box chiqaradi. Masalan, bitta odam atrofida 4 ta box chiqishi mumkin. NMS confidence score va IoU asosida eng yaxshi boxni qoldiradi, qolgan juda o'xshash boxlarni olib tashlaydi.

NMS ishlamasa, natijada bitta obyekt atrofida ko'plab boxlar ko'rinib qoladi. NMS orqali output tozalanadi.

NMS threshold odatda 0.4–0.5 atrofida bo'lishi mumkin. Threshold — chegara qiymat.

Bounding Box formatlari va IoU

Object Detectionda bounding box turli dataset va model formatlarida saqlanishi mumkin. Eng ko'p uchraydigan formatlar: Pascal VOC, YOLO va COCO.

Detection output misoli

Detection output misol sifatida quyidagicha ko'rinadi:

person 0.97

car 0.92

dog 0.85

Bu yerda model uchta obyektни topgan:

person → 97% ishonch

car → 92% ishonch

dog → 85% ishonch

Har bir obyekt uchun class label va confidence score bor. Real outputda ularga bounding box koordinatalari ham qo'shiladi.

Pascal VOC format

Pascal VOC formatda bounding box ikki burchak koordinatasi bilan ifodalanadi:

`[x_min, y_min, x_max, y_max]`

Bu yerda:

`x_min` → boxning chap tomoni

`y_min` → boxning yuqori tomoni

`x_max` → boxning o'ng tomoni

`y_max` → boxning past tomoni

Bu format mutlaq pixel qiymatlarida beriladi.

Mutlaq pixel qiymati — rasmning haqiqiy pixel koordinatasida berilgan son. Masalan, 192, 96, 448, 384.

Pascal VOC format misoli:

`[192, 96, 448, 384]`

Bu box chapdan 192-pixeldan boshlanadi, yuqoridan 96-pixeldan boshlanadi, o'ng tomoni 448-pixelda, past tomoni 384-pixelda tugaydi.

Pascal VOC formatda width va height to'g'ridan-to'g'ri berilmaydi. Ularni hisoblash kerak:

```
width = x_max - x_min  
height = y_max - y_min
```

Misol:

```
width = 448 - 192 = 256  
height = 384 - 96 = 288
```

YOLO format

YOLO formatda bounding box markaz koordinatasi va o'lcham orqali beriladi:

```
[x_c, y_c, width, height]
```

Bu yerda:

$x_c \rightarrow$ box markazining x koordinatasi

$y_c \rightarrow$ box markazining y koordinatasi

$width \rightarrow$ box kengligi

$height \rightarrow$ box balandligi

YOLO format ko'pincha normalized qiymatda bo'ladi.

Normalized — qiymatlar 0 dan 1 gacha oraliqqa keltirilgan degani.

Masalan:

```
[0.50, 0.50, 0.40, 0.60]
```

Bu quyidagicha tushuniladi:

$x_center = 0.50 \rightarrow$ box markazi rasm kengligining o'rtasida
 $y_center = 0.50 \rightarrow$ box markazi rasm balandligining o'rtasida
 $width = 0.40 \rightarrow$ box rasm kengligining 40% qismini egallaydi
 $height = 0.60 \rightarrow$ box rasm balandligining 60% qismini egallaydi

YOLO formatda 0 eng chap yoki eng yuqori tomonni, 1 eng o'ng yoki eng past tomonni bildiradi. 0.5 esa markazni bildiradi.

YOLO qiymatlarining ma'nosi

YOLO formatidagi asosiy sonlar:

x_center
 y_center
 $width$
 $height$

x_center — box markazi rasmning chapidan qanchalik uzoqda ekanini bildiradi. 0 eng chap, 1 eng o'ng, 0.5 aynan o'rta.

y_center — box markazi rasmning yuqorisidan qanchalik pastda ekanini bildiradi. 0 eng yuqori, 1 eng past, 0.5 aynan o'rta.

$width$ — box rasm kengligining qanchalik foizini egallashini bildiradi. Masalan, 0.5 rasm kengligining yarmi degani.

$height$ — box rasm balandligining qanchalik foizini egallashini bildiradi. Masalan, 0.3 rasm balandligining 30% qismi degani.

YOLO format training uchun juda qulay, chunki turli o'lchamdagi rasmlarda boxlar 0–1 oralig'ida bir xil scale'da saqlanadi.

Scale — qiymatlarning umumiy o'lchov oraliği.

COCO format

COCO formatda bounding box chap yuqori burchak va o'lcham bilan beriladi:

`[x_min, y_min, width, height]`

Bu yerda:

`x_min` → boxning chap boshlanish koordinatasi

`y_min` → boxning yuqori boshlanish koordinatasi

`width` → box kengligi

`height` → box balandligi

COCO format ham mutlaq pixel qiymatlarida bo'ladi.

Misol:

`[192, 96, 256, 288]`

Bu box chapdan 192-pixeldan, yuqoridan 96-pixeldan boshlanadi.

Kengligi 256 pixel, balandligi 288 pixel.

COCO format Pascal VOC'dan farq qiladi. Pascal VOC oxirgi burchakni beradi, COCO esa boshlanish nuqtasi va o'lchamni beradi.

Pascal VOC:

`[x_min, y_min, x_max, y_max]`

COCO:

`[x_min, y_min, width, height]`

BBox formatlarining bir-biriga bog‘lanishi

Misol sifatida quyidagi qiymatlar olinsa:

YOLO:	0.50	0.50	0.40	0.60
Pascal VOC:	192	96	448	384
COCO:	192	96	256	288

Bu uchala format bitta boxni turli ko‘rinishda ifodalaydi.

Agar rasm o‘lchami 640×480 deb olinsa:

$x_center = 0.50 \times 640 = 320$

$y_center = 0.50 \times 480 = 240$

$width = 0.40 \times 640 = 256$

$height = 0.60 \times 480 = 288$

YOLO markaz va o‘lcham beradi. Pascal VOC chap-yuqori va o‘ng-past koordinatalarni beradi.

Pascal VOCga o‘tish:

$x_min = x_center - width / 2 = 320 - 128 = 192$

$y_min = y_center - height / 2 = 240 - 144 = 96$

$x_max = x_center + width / 2 = 320 + 128 = 448$

$$y_{\max} = y_{\text{center}} + \text{height} / 2 = 240 + 144 = 384$$

COCO formatga o'tish:

$$x_{\min} = 192$$

$$y_{\min} = 96$$

$$\text{width} = 256$$

$$\text{height} = 288$$

Shu sababli bir xil obyekt boxi datasetga qarab boshqa formatda yozilishi mumkin. Model training va evaluation paytida formatlarni adashtirmaslik kerak.

IoU — Intersection over Union

IoU Object Detectionda predicted box va actual box qanchalik mos tushganini o'lchaydi.

IoU formulasi:

$$\text{IoU} = \text{Kesishuv maydoni} \div \text{Birlashuv maydoni}$$

Kesishuv maydoni — predicted box va actual box ustma-ust tushgan qism.

Birlashuv maydoni — ikkala box birga egallagan umumiy hudud.

IoU qiymati 0.0 dan 1.0 gacha bo'ladi:

0.0 → umuman mos emas

1.0 → mukammal mos

IoU qiymatlarini baholash:

$\text{IoU} > 0.5 \rightarrow \text{yaxshi}$

$\text{IoU} > 0.75 \rightarrow \text{juda yaxshi}$

$\text{IoU} = 1.0 \rightarrow \text{perfect, ya'ni mukammal}$

Perfect — ideal yoki mukammal degani.

Agar model classni to'g'ri topgan bo'lsa ham, bounding box noto'g'ri joylashgan bo'lsa, detection to'liq yaxshi deb hisoblanmaydi. Object Detectionda class ham, box ham to'g'ri bo'lishi kerak.

Detection turlari: One-Stage va Two-Stage

Object Detection modellari ikki katta guruhga bo'linadi:

One-Stage Detectors

Two-Stage Detectors

Detector — obyektни topadigan model.

One-Stage Detectors

One-Stage Detectors rasmni networkdan bir marta o'tkazadi va shu jarayonda bounding box ham, class ham bir vaqtda aniqlanadi.

Network — neural network, ya'ni neyron tarmoq.

One-Stage yondashuvda model to'g'ridan-to'g'ri shunday natija beradi:

BBox + Class + Confidence

Bu turdagi modellarga quyidagilar kiradi:

YOLO

SSD

RetinaNet

YOLO — You Only Look Once. O‘zbekcha mazmuni: model rasmga bir marta qarab obyektlarni topadi.

SSD — Single Shot Detector. Bitta o‘tishda detection qiladigan model.

RetinaNet — One-Stage detector bo‘lib, focal loss yordamida qiyin obyektlarni yaxshiroq o‘rganishga qaratilgan model.

Focal loss — oson va qiyin misollar orasidagi muvozanatni yaxshilashga yordam beradigan loss function.

One-Stage detectorlarning afzalliklari:

tez ishlaydi
real-time ishlashi osonroq
deployment qilish qulay
mobile va edge qurilmalar uchun mos

Real-time — real vaqt rejimida tez ishlash.

Deployment — modelni real tizimga chiqarish.

Edge device — telefon, kamera, Raspberry Pi, Jetson kabi kichik qurilmalar.

One-Stage detectorlarning kamchiligi:

kichik obyektlarda aniqlik ba'zan pastroq bo'ladi juda murakkab sahnalarda xato ko'proq bo'lishi mumkin

Kichik obyekt — rasmda juda kichik joy egallagan obyekt. Masalan, uzoqdagi odam yoki kichik dron.

Two-Stage Detectors

Two-Stage Detectors detectionni ikki bosqichda bajaradi.

Birinchi bosqich:

Region Proposals

Region Proposal — obyekt bo'lishi ehtimoli bor candidate boxlarni topish.

Candidate box — obyekt bo'lishi mumkin bo'lgan taxminiy hudud.

Ikkinchi bosqich:

Har bir region uchun classification

Ya'ni model avval “obyekt bo'lishi mumkin bo'lgan joylarni” topadi. Keyin har bir regionni classga ajratadi va boxni aniqlashtiradi.

Two-Stage detectorlarga quyidagilar kiradi:

R-CNN

Fast R-CNN

Faster R-CNN

R-CNN — Region-based Convolutional Neural Network.

Fast R-CNN — R-CNNning tezroq varianti.

Faster R-CNN — region proposal network orqali regionlarni tezroq topadigan model.

Two-Stage detectorlarning afzalliklari:

yuqori aniqlik beradi

kichik obyektlarni yaxshiroq topadi

tibbiyot va aniqlik muhim sohalarda foydali

Kamchiliklari:

sekinroq

real-time qilish qiyinroq

architecture murakkabroq

deployment og'irroq

One-Stage va Two-Stage umumiy farqi

One-Stage:

Rasm → Model → BBox + Class

Two-Stage:

Rasm → Candidate regions → Har bir region

classification → Final detection

One-Stage tezlikka ko'proq mos. Two-Stage aniqlikka ko'proq mos.

Agar kamera stream real-time ishlashi kerak bo'lsa, YOLO kabi One-Stage model yaxshi tanlov bo'ladi. Agar tibbiy tasvirda yuqori aniqlik kerak bo'lsa, Faster R-CNN kabi Two-Stage model foydali bo'ladi.

Computer Vision vazifalari daraxti

Computer Vision vazifalari daraxt ko'rinishida uchta katta guruhga bo'linadi:

Computer Vision

- ├ Classification
- ├ Object Detection
- └ Segmentation

Classification turlari

Classification ichida uchta tur bor:

Binary

Multiclass

Multilabel

Binary Classification — faqat ikkita class orasidan tanlash.

Misol:

cat yoki dog

yes yoki no

normal yoki diseased

Multiclass Classification — ko'p class orasidan faqat bittasini tanlash.

Misol:

airplane

car

bird

cat

dog

Multilabel Classification — bitta rasmga bir nechta label tanlash.

Misol:

person + bicycle + dog

Object Detection turlari

Object Detection ikki turga bo'linadi:

One-Stage

Two-Stage

One-Stage modellarga:

YOLO

SSD

RetinaNet

Two-Stage modellarga:

R-CNN

Fast R-CNN

Faster R-CNN

Bu daraxt Object Detection mavzusi Classificationdan keyingi alohida yoʻnalish ekanini koʻrsatadi.

Segmentation turlari

Segmentation uch turga boʻlinadi:

Semantic

Instance

Panoptic

Semantic Segmentation — har bir pixelga class beradi, lekin bir xil classdagi alohida obyektlarni ajratmaydi.

Instance Segmentation — har bir obyekt instance'ini alohida mask bilan ajratadi.

Panoptic Segmentation — semantic va instance segmentationni birlashtiradi. Ya'ni ham pixel classini, ham alohida obyektlarni ajratadi.

Panoptic — umumiy va toʻliq koʻrinishda ajratish degani.

Modellar taqqoslash jadvali

Object Detection modellarini tanlashda tezlik, mAP va ishlatish joyi muhim hisoblanadi.

FPS — Frames Per Second. Oʻzbekcha izohi: sekundiga nechta kadr qayta ishlanishi. FPS katta boʻlsa, model tez ishlaydi.

mAP — mean Average Precision. Object Detectionda asosiy aniqlik metriclaridan biri. mAP katta bo'lsa, model odatda yaxshiroq detection qiladi.

YOLOv8n

YOLOv8n — YOLOv8ning eng yengil variantlaridan biri. n odatda nano variantni bildiradi.

Tur:

One-Stage

Tezlik:

~200 FPS

mAP:

O'rta

Qachon ishlatish:

Mobile / Edge devices

YOLOv8n juda tez ishlaydi, shuning uchun mobile, edge device, real-time camera va yengil deployment uchun qulay. Lekin mAP o'rta darajada bo'lgani uchun juda yuqori aniqlik kerak bo'lgan vazifalarda yetarli bo'lmasligi mumkin.

YOLOv8x

YOLOv8x — YOLOv8ning katta va kuchliroq varianti. x odatda extra large modelni bildiradi.

Tur:

One-Stage

Tezlik:

~30 FPS

mAP:

Yuqori

Qachon ishlatish:

Server, aniqlik kerak bo'lganda

YOLOv8x YOLOv8ndan sekinroq, lekin aniqligi yuqoriroq. Serverda ishlatish uchun mos. Agar GPU kuchli bo'lsa va yuqori accuracy kerak bo'lsa, YOLOv8x yaxshi variant bo'ladi.

SSD300

SSD300 — Single Shot Detectorning 300×300 input bilan ishlaydigan varianti.

Tur:

One-Stage

Tezlik:

~60 FPS

mAP:

O'rta

Qachon ishlatish:

Embedded, embedded camera

Embedded — kichik qurilma ichiga joylashtirilgan tizim. Masalan, smart camera yoki sanoat qurilmasi.

SSD300 tezlik va soddalik uchun qulay, lekin zamonaviy YOLO modellari ko'p hollarda kuchliroq natija beradi.

Faster R-CNN

Faster R-CNN — Two-Stage detector. Yuqori aniqlik beradigan model hisoblanadi.

Tur:

Two-Stage

Tezlik:

~10 FPS

mAP:

Juda yuqori

Qachon ishlatish:

Tibbiyot, yuqori aniqlik

Faster R-CNN real-time uchun uncha qulay emas, lekin aniqlik muhim bo'lgan sohalarda yaxshi ishlaydi. Masalan, tibbiy tasvirlar, kichik obyektlarni topish yoki ilmiy tahlil.

Mask R-CNN

Mask R-CNN — Faster R-CNN asosida qurilgan va segmentation mask ham chiqaradigan model.

Tur:

Two-Stage

Tezlik:

~5 FPS

mAP:

Eng yuqori

Qachon ishlatish:

Segmentation ham kerak bo'lsa

Mask R-CNN faqat bounding box emas, obyekt maskini ham chiqaradi. Shu sababli u Object Detection va Instance Segmentation orasidagi kuchli model hisoblanadi.

Model tanlash bo'yicha umumiy qoida

Tezlik kerak → YOLOv8n, SSD300

Yuqori aniqlik kerak → YOLOv8x, Faster R-CNN

Segmentation ham kerak → Mask R-CNN

Edge device kerak → YOLOv8n

Tibbiyot va aniq tahlil kerak → Faster R-CNN yoki Mask R-CNN

Model tanlashda faqat accuracy emas, FPS, model size, deployment muhiti va vazifa turi ham hisobga olinadi.

Datasetlar va baholash metrikalari

Object Detection projectida modelni train qilish uchun box annotationli dataset kerak bo'ladi. Ya'ni har bir obyekt uchun class label va bounding box berilgan bo'lishi kerak.

Mashhur Object Detection datasetlar

MS COCO

MS COCO Object Detection uchun eng mashhur datasetlardan biri.

Asosiy xususiyatlari:

330K rasm

80 class

1.5M+ instance

Instance — alohida obyekt nusxasi. Masalan, bitta rasmda 5 ta odam bo'lsa, 5 ta person instance bor.

COCO dataset real hayotga yaqin sahnalarni o'z ichiga oladi. Unda odamlar, mashinalar, hayvonlar, uy buyumlari va boshqa ko'plab obyektlar mavjud.

COCO benchmark sifatida juda ko'p ishlatiladi. Benchmark — modelni solishtirish uchun ishlatiladigan standart test muhiti.

Pascal VOC

Pascal VOC klassik Object Detection datasetlaridan biri.

Asosiy xususiyatlari:

20 class

2007 / 2012 benchmark

Pascal VOC beginnerlar uchun tushunarliroq, chunki classlar soni COCOga qaraganda kamroq. Bu dataset Object Detection asoslarini o'rganish uchun juda qulay.

Open Images

Open Images — Google tomonidan taqdim etilgan katta dataset.

Asosiy xususiyatlari:

600 class

9M rasm

Bu juda katta va xilma-xil dataset. Katta classlar soni sababli real-world detection vazifalari uchun foydali.

KITTI

KITTI asosan avtomobil va self-driving sohasida ishlatiladi.

Unda quyidagi obyektlar muhim:

pedestrian

car

cyclist

Pedestrian — piyoda.

Cyclist — velosipedchi.

KITTI self-driving, autonomous driving va road scene understanding uchun muhim dataset hisoblanadi.

VisDrone

VisDrone dron tasvirlari uchun dataset.

Dron tasvirlarida obyektlar ko‘pincha juda kichik ko‘rinadi. Shu sababli VisDrone kichik obyektlarni detection qilishni o‘rganish uchun foydali.

Dron tasvirlarida quyidagi muammolar bo‘ladi:

obyektlar kichik

kamera yuqoridan qaraydi

odamlar va mashinalar zich joylashadi

fon murakkab bo‘ladi

Object Detection metrikalari

Object Detectionda modelni baholash Image Classificationga qaraganda murakkabroq. Chunki model classni ham, box joylashuvini ham to‘g‘ri topishi kerak.

Asosiy metrikalar:

[mAP@0.5](#)

[mAP@0.5:0.95](#)

Precision

Recall

FPS

IoU

Confidence Score

[mAP@0.5](#)

[mAP@0.5](#) — IoU threshold 0.5 bo‘lganda o‘rtacha aniqlik.

Threshold — chegara qiymat.

Agar predicted box va ground truth box IoU qiymati 0.5 dan yuqori bo‘lsa, detection to‘g‘ri deb hisoblanadi.

[mAP@0.5](#) ko‘p datasetlarda asosiy metric sifatida ishlatiladi.

[mAP@0.5:0.95](#)

[mAP@0.5:0.95](#) — COCO standarti. Bu metric 10 xil IoU threshold bo‘yicha o‘rtacha natijani oladi.

Thresholdlar:

0.50

0.55

0.60

...

0.95

Bu metric [mAP@0.5](#) ga qaraganda qattiqroq va aniqroq baholaydi. Chunki model boxni faqat taxminan emas, ancha aniq joylashtirishi kerak bo'ladi.

Precision

Precision formulasi:

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

TP — True Positive. Model obyektни to'g'ri topgan holat.

FP — False Positive. Model obyekt bor deb aytgan, lekin aslida noto'g'ri bo'lgan holat.

Precision model aytgan detectionlar ichida nechta to'g'ri ekanini bildiradi.

Agar precision yuqori bo'lsa, model kamroq noto'g'ri alarm beradi.

Recall

Recall formulasi:

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

FN — False Negative. Aslida obyekt bor, lekin model topa olmagan holat.

Recall model barcha haqiqiy obyektlardan nechtasini topganini bildiradi.

Agar recall yuqori bo'lsa, model obyektlarni ko'proq topadi va kamroq o'tkazib yuboradi.

FPS

FPS — Frames Per Second. Model sekundiga nechta frame qayta ishlashini bildiradi.

Real-time webcam uchun FPS yuqori bo'lishi kerak. Tibbiy rasm tahlilida esa FPS unchalik muhim emas, chunki bitta rasmni aniq tahlil qilish tezlikdan muhimroq bo'ladi.

Summary jadvali asosida umumiy tushunchalar

Object Detection bo'yicha asosiy tushunchalar quyidagicha umumlashtiriladi.

Object Detection

Object Detection — obyekt va uning joylashuvini topish.

Misollar:

YOLO

Faster R-CNN

SSD

RetinaNet

Object Detection outputi:

class label + bounding box + confidence score

Bounding Box

Bounding Box — obyektни o‘rab turuvchi to‘rtburchak.

Misol format:

(x_c, y_c, w, h)

Bu YOLO formatga yaqin ko‘rinish.

Class Label

Class Label — obyekt turi.

Misollar:

car

person

dog

cat

bicycle

Confidence

Confidence — modelning ishonch darajasi.

Range:

0.0 - 1.0

0.9 qiymat 90% ishonch degani.

IoU

IoU — predicted box va actual box o'xshashligini o'lchaydi.

$\text{IoU} > 0.5 \rightarrow \text{yaxshi}$

NMS

NMS — ortiqcha boxlarni olib tashlash.

Threshold:

$0.4 - 0.5$

Agar bitta obyekt atrofida bir nechta box chiqsa, NMS eng ishonchli boxni qoldiradi.

One-Stage

One-Stage detectorlar tez ishlaydi va rasmni bir marta networkdan o'tkazadi.

Misollar:

YOLO

SSD

Two-Stage

Two-Stage detectorlar ikki bosqichda ishlaydi va aniqroq bo'ladi.

Misol:

Faster R-CNN

mAP

mAP — Object Detection uchun asosiy metric.

Misol:

COCO [mAP@0.5](#)

mAP model detection sifatini umumiy baholashga yordam beradi.

Confidence Score batafsil

Confidence Score modelning detection natijasiga qanchalik ishonishini ko'rsatadi.

Notation:

conf

Range:

0.0 → 1.0

Formula ko'rinishi:

$\text{conf} = P(\text{object}) \times \text{IoU}(\text{pred}, \text{truth})$

Bu yerda:

$P(\text{object}) \rightarrow$ model obyekt borligiga bergan ehtimollik

$\text{IoU}(\text{pred}, \text{truth}) \rightarrow$ predicted box va truth box mosligi

Truth box — ground truth box, ya'ni haqiqiy annotationdagi box.

Confidence score faqat class probability emas. U obyekt borligi va box sifatini ham ifodalashi mumkin.

Confidence qiymatlari quyidagicha talqin qilinadi:

> 0.7	$\rightarrow$ juda ishonchli, ko'rsatiladi
$0.5 - 0.7$	$\rightarrow$ o'rta, odatda ko'rsatiladi
$0.25 - 0.5$	$\rightarrow$ kam ishonch, ba'zan ko'rsatiladi
< 0.25	$\rightarrow$ ignore qilinadi

Ignore — e'tiborga olinmaydi, tashlab ketiladi.

Agar threshold 0.5 qilib qo'yilsa, 0.5 dan past confidence scorega ega detectionlar ko'rsatilmaydi.

Threshold tanlash vazifaga bog'liq:

xavfsizlik tizimi $\rightarrow$ recall muhim bo'lsa, threshold pastroq
aniqlik muhim bo'lsa $\rightarrow$ threshold yuqoriroq

Recall muhim bo'lganda obyektни o'tkazib yubormaslik kerak.

Precision muhim bo'lganda noto'g'ri detectionlar kam bo'lishi kerak.

FPS — Frames Per Second

FPS — Frames Per Second. O‘zbekcha izohi: model bir sekundda nechta frame yoki rasmni qayta ishlay oladi.

Notation:

FPS

Formula:

$$\text{FPS} = 1 / \text{inference_time(seconds)}$$

Inference time — bitta rasm yoki frame uchun model javob berish vaqti.

Agar bitta frame inference qilish uchun 0.05 sekund ketsa:

$$\text{FPS} = 1 / 0.05 = 20 \text{ FPS}$$

Unit:

Frames per second

FPS real-time video va kamera tizimlarida juda muhim.

Turli vazifalar uchun kerakli FPS:

Real-time webcam → 30+ FPS

Video tahlil → 15+ FPS

Bitta rasm tahlil → FPS muhim emas

Medical imaging → FPS muhim emas

Real-time webcam uchun 30+ FPS kerak, chunki kamera oqimi silliq ko‘rinishi va natija kechikmasligi kerak.

Video tahlil uchun 15+ FPS ko‘pincha yetarli bo‘ladi, chunki har bir frame emas, harakat yoki umumiy vaziyat tahlil qilinadi.

Bitta rasm tahlilida FPS muhim emas, chunki model faqat bitta rasmga javob beradi. Bu yerda accuracy ko‘proq muhim.

Medical imagingda ham FPS muhim emas. Chunki tibbiy diagnosisda modelning tezligidan ko‘ra aniqligi muhimroq bo‘ladi.

mAP — mean Average Precision

mAP — mean Average Precision. Object Detectionda modelni baholash uchun ishlatiladigan asosiy metriclardan biri.

Notation:

mAP

Formula:

$$mAP = (1 / N) \times \sum AP_i$$

Bu yerda:

$N \rightarrow$ classlar soni

$AP_i \rightarrow$ i-class uchun Average Precision

$\sum \rightarrow$ yig‘indi belgisi

AP — Average Precision. Bitta class uchun precision-recall curve asosida hisoblanadigan aniqlik qiymati.

Precision-recall curve — precision va recall orasidagi bog‘lanishni ko‘rsatadigan egri chiziq.

mAP barcha classlar AP qiymatlarining o‘rtachasi hisoblanadi.

Range:

0.0 → 1.0

Yoki foizda:

0% → 100%

mAP versiyalari:

[mAP@0.5](#)

[mAP@0.5:0.95](#)

[mAP@0.5](#) IoU threshold 0.5 bo‘lganda hisoblanadi.

[mAP@0.5:0.95](#) esa IoU 0.5 dan 0.95 gacha bo‘lgan bir nechta threshold bo‘yicha o‘rtacha olinadi.

mAP hisoblash misoli

Misol sifatida uchta class bor:

person → AP = 0.85

car → AP = 0.78

dog → AP = 0.62

mAP hisoblash:

$$\text{mAP} = (0.85 + 0.78 + 0.62) / 3$$

$$\text{mAP} = 2.25 / 3$$

$$\text{mAP} = 0.75$$

Bu model umumiy detection bo'yicha 0.75 mAP olganini bildiradi.
Foizda bu 75% ga teng.

mAP qiymatini baholash

[mAP@0.5](#) qiymatiga qarab natija quyidagicha baholanadi:

- > 0.80 → Ajoyib
- 0.60–0.80 → Yaxshi
- 0.40–0.60 → O'rtacha
- < 0.40 → Yaxshilash kerak

Agar mAP 0.85 bo'lsa, model juda yaxshi ishlayapti. Agar mAP 0.75 bo'lsa, yaxshi natija. Agar mAP 0.50 bo'lsa, o'rtacha. Agar mAP 0.30 bo'lsa, modelni yaxshilash kerak.

mAPni oshirish uchun quyidagilar qilinadi:

- ko'proq va sifatli data yig'ish
- annotation xatolarini tozalash
- model architecture tanlash
- image size oshirish
- augmentation qilish
- training epochlarni moslash
- confidence va NMS thresholdni sozlash

IoU — Intersection over Union batafsil

IoU Object Detectionda bounding box sifatini baholash uchun ishlatiladi.

Notation:

IoU

Formula:

$$\text{IoU} = \text{Area}(A \cap B) \div \text{Area}(A \cup B)$$

Bu yerda:

$A \rightarrow$ predicted box

$B \rightarrow$ ground truth box

$A \cap B \rightarrow$ ikki box kesishgan hudud

$A \cup B \rightarrow$ ikki box birlashgan umumiy hudud

Range:

$0.0 \rightarrow 1.0$

Threshold:

Odatda 0.5 ishlatiladi

IoU qiymatlari ma'nosi:

1.0 $\rightarrow$ mukammal, boxlar aynan bir xil

> 0.75 $\rightarrow$ juda yaxshi

> 0.5 → yaxshi, standart threshold
0.3 – 0.5 → qabul qilinishi mumkin, lekin
yaxshilash kerak
< 0.3 → yomon, box noto'g'ri joylashgan

Agar IoU 1.0 bo'lsa, predicted box ground truth box bilan aynan bir xil. Bu ideal holat.

Agar IoU 0.8 bo'lsa, box juda yaxshi joylashgan.

Agar IoU 0.55 bo'lsa, ko'p detection benchmarklarida to'g'ri detection sifatida qabul qilinadi.

Agar IoU 0.35 bo'lsa, obyekt taxminan topilgan, lekin box aniq emas.

Agar IoU 0.2 bo'lsa, box noto'g'ri joylashgan hisoblanadi.

IoU Object Detectionda juda muhim, chunki model faqat classni topishi yetarli emas. Box obyektga mos joylashishi kerak.

Misol:

Model dog deb to'g'ri topdi
Lekin box dogdan ancha chetda turibdi
→ class to'g'ri, lekin IoU past
→ detection sifati yomon

Shuning uchun Object Detectionda yaxshi model quyidagilarni birga bajarishi kerak:

obyekt classini to'g'ri topish
boxni to'g'ri joylashtirish
confidence score'ni mos berish

ortiqcha boxlarni NMS bilan tozalash

Yakuniy umumiy tushuncha

Object Detection Computer Vision ichidagi asosiy va amaliy jihatdan juda muhim vazifalardan biri hisoblanadi. Image Classification faqat rasmda nima borligini aytadi. Object Detection esa nima borligini va qayerda joylashganini ham ko'rsatadi. Segmentation esa obyektни pixel darajasida ajratadi.

Object Detection outputi odatda uchta asosiy qismdan iborat bo'ladi:

Class Label

Bounding Box

Confidence Score

Class Label obyekt turini bildiradi. Bounding Box obyekt joylashuvini ko'rsatadi. Confidence Score modelning predictionga qanchalik ishonishini bildiradi.

Bounding box turli formatlarda yoziladi:

Pascal VOC → [x_min, y_min, x_max, y_max]

YOLO → [x_center, y_center, width, height]

COCO → [x_min, y_min, width, height]

YOLO format normalized 0–1 oraliqda ishlaydi. Pascal VOC va COCO ko'pincha mutlaq pixel qiymatlaridan foydalanadi.

Object Detectionda IoU predicted box va ground truth box qanchalik mosligini o'lchaydi. IoU 0.5 dan yuqori bo'lsa, odatda yaxshi

detection deb olinadi. IoU 1.0 bo'lsa, box mukammal mos tushgan bo'ladi.

Detectorlar One-Stage va Two-Stage turiga bo'linadi. One-Stage detectorlar tez va real-time uchun qulay. YOLO, SSD va RetinaNet shu turga kiradi. Two-Stage detectorlar aniqroq, lekin sekinroq. R-CNN, Fast R-CNN va Faster R-CNN shu turga kiradi.

Model tanlashda tezlik va aniqlik o'rtasida muvozanat bo'ladi. YOLOv8n juda tez, lekin mAP o'rta. YOLOv8x sekinroq, lekin aniqligi yuqoriroq. Faster R-CNN juda aniq, lekin sekin. Mask R-CNN segmentation ham kerak bo'lganda ishlatiladi.

Object Detection datasetlari ichida MS COCO, Pascal VOC, Open Images, KITTI va VisDrone muhim hisoblanadi. COCO katta va real-world dataset. Pascal VOC klassik benchmark. KITTI self-driving uchun, VisDrone esa dron tasvirlari va kichik obyektlar uchun ishlatiladi.

Baholashda mAP, Precision, Recall, FPS, Confidence Score va IoU ishlatiladi. mAP model detection sifatining asosiy metrici hisoblanadi. FPS esa modelning tezligini ko'rsatadi. Real-time webcam uchun 30+ FPS kerak bo'ladi, tibbiy tasvirlarda esa FPSdan ko'ra aniqlik muhimroq.

To'liq Object Detection jarayoni quyidagicha tushuniladi:

Rasm modelga kiradi

↓

Model obyektlarni qidiradi

↓

Har bir obyekt uchun class label chiqaradi

↓

Har bir obyekt uchun bounding box beradi

↓

Har bir detection uchun confidence score beradi

↓

IoU orqali box sifati baholanadi

↓

NMS ortiqcha boxlarni olib tashlaydi

↓

Final detection output hosil bo'ladi

Object Detection real hayotda xavfsizlik kamerasi, self-driving avtomobil, tibbiy tasvir, dron monitoringi, sanoat nazorati, robototexnika va smart camera tizimlarida ishlatiladi. Bu yo'nalishda asosiy maqsad rasm yoki video ichidagi obyektlarni topish, ularni classlarga ajratish va aniq joylashuvini ko'rsatishdan iborat.